СОФИЙСКИ УНИВЕРСИТЕТ „СВ. КЛИМЕНТ ОХРИДСКИ“
ФАКУЛТЕТ ПО МАТЕМАТИКА И ИНФОРМАТИКА

МАГИСТЪРСКА ТЕЗА

АНАЛИЗ НА ПРОСТРАНСТВАТА ОТ РЕШЕНИЯ И КОНФИГУРАЦИИ В ЛИНЕЙНИ МНОГОКРИТЕРИАЛНИ СИСТЕМИ ЗА ОЦЕНКА

Дипломант: Марин Стоянов
Факултетен № 5MI3300010
МП: Вероятности, актюерство и статистика
Специалност: Математика

Научен ръководител: доц. д-р Валерия Симеонова
Катедра „Информационни технологии“

София, 2026 г.

Съдържание

Увод 4
Актуалност и мотивация 4
Проблемна постановка 4
Обект, предмет и обхват на изследването 5
Изследователски въпроси 6
Цел и задачи на дипломната работа 6
Методи и очаквани резултати 6
Структура на дипломната работа 7
Речник на използваната терминология 8
Глава 1. Литературен обзор и теоретична рамка 10
1.1. Линейни многокритериални системи и адитивни модели на полезност 10
1.2. Нормализация, теглови структури и композитни индикатори 11
1.3. Пространства от решения и конфигурационен прочит 12
1.4. Линейно и смесено целочислено оптимиране за допустими и минимални конфигурации 13
1.5. Геометрия и генериране на извадки от пространства на решения и тегла 14
1.6. Анализ на чувствителността и устойчивостта при вариращи тегла 15
1.7. Парето анализ, представяне и визуализация на множества от решения 16
1.8. Достатъчни комбинации, съвместна поява и взаимозаменяемост на индикатори 17
1.9. Клъстеризация, профилиране, валидиране и стабилност на клъстерите 18
1.10. Синтетични експерименти и възпроизводими изчислителни изследвания 19
1.11. Синтез на литературата, установени дефицити и място на настоящата работа 19
Глава 2. Изследователска рамка и математически модел 21
2.1. Изследователска логика и въпроси 21
2.2. Формално описание на индикаторите 21
2.3. Формално описание на теглата 22
2.4. Линейна оценъчна функция 22
2.5. Оценъчни прагове и класове резултати 22
2.6. Ограничения и допустими области 23
2.7. Представяне на решения, конфигурации и оценъчни системи 23
2.8. Разграничение между локален и глобален анализ 23
2.9. Допускания и граници на модела 24
Глава 3. Методология за анализ на пространствата от решения и конфигурации 25
3.1. Общ изследователски процес 25

3.2. Генериране на синтетични данни и сценарии 26
3.3. Локален анализ при фиксирани тегла 26
3.4. Глобален анализ при вариращи тегла 27
3.5. Метрики и Парето анализ 27
3.6. Анализ на чувствителността и устойчивостта 28
3.7. Клъстеризация и профилиране 28
3.8. Честота, съвместна поява и взаимозаменяемост 29
3.9. Критерии за валидиране и интерпретация 29
3.10. Мащабируемост и възпроизводимост 29
Глава 4. Проектиране и реализация на софтуерния инструмент 31
4.1. Функционални и нефункционални изисквания 31
4.2. Архитектура на инструмента 31
4.3. Входни параметри и потребителски сценарии 32
4.4. Модул за генериране на данни 32
4.5. Реализация на локалния модул 33
4.6. Реализация на глобалния модул 34
4.7. Реализация на аналитичния модул 34
4.8. Визуализации и отчети 35
4.9. Съхранение и възпроизводимост на експериментите 35
4.10. Шаблон за анализ на потребителски данни 35
4.11. Тестване и техническа верификация 36
Глава 5. Експериментални изследвания и резултати 37
5.1. Дизайн на експериментите 38
5.2. Референтни сценарии и базова проверка 39
5.3. Експерименти с различен брой активни индикатори 40
5.4. Експерименти с различни теглови структури 41
5.5. Експерименти с различни прагове и ограничения 42
5.6. Резултати от локалния анализ 43
5.7. Резултати от профилирането на оценъчните класове, съвместната поява и взаимозаменяемостта 43
5.8. Резултати от глобалния анализ 46
5.9. Сравнение на локални и глобални резултати 49
5.10. Изчислителна ефективност и възпроизводимост 50
Глава 6. Обсъждане на резултатите 51
6.1. Отговори на изследователските въпроси 51

6.2. Съпоставка с разгледаните подходи 51
6.3. Интерпретация на типовете конфигурации и класовете системи 52
6.4. Научен и приложен принос 52
6.5. Ограничения и заплахи за валидността 53
Заключение 54
Обобщение на постигнатите резултати 54
Основни приноси 54
Насоки за бъдещо развитие 55
Приложения 56
Приложение 1. Описание на входните данни 56
Приложение 2. Параметри на експерименталния сценарий 57
Приложение 3. Инсталиране и работа със софтуерния инструмент 58
Приложение 4. Шаблон JSON 65
Приложение 5. Допълнителни резултатни таблици 67
Използвани фигури в текста (без приложенията) 68
Използвани таблици в текста (без приложенията) 68
Използвана литература 69

Увод

Актуалност и мотивация

Линейните многокритериални системи за оценка се използват, когато един резултат трябва да обобщи множество измерими характеристики. При нормализирани индикатори и предварително зададени тегла крайният резултат обикновено се получава чрез претеглена сума. Този модел е лесен за интерпретация и приложение, но единичната крайна оценка не показва какви различни комбинации от индикаторни стойности могат да доведат до нея и доколко изводът се запазва при промяна на теглата [14], [17].

Настоящата работа насочва анализа от отделната числова оценка към пространството от решения и конфигурации. Разграничават се две допълващи се перспективи. При локалния анализ теглата на конкретна индикаторна система са фиксирани и се изследват стойностите на индикаторите: кои конфигурации покриват зададен праг, какво не достига на конфигурациите под прага и какви алтернативи дават близки до максималните резултати. При глобалния анализ наборът от данни и броят на индикаторите се запазват, а се изменят теглата, за да се оцени структурата на самата индикаторна система.

Тази постановка е важна практически, защото позволява едновременно да се отговори на въпроса „как работи конкретната система?“ и на по-общия въпрос „как е устроена системата от индикатори и колко от тях реално са необходими за балансирана оценка?“. Така оптимизационният, чувствителностният и конфигурационният анализ се обединяват в обща възпроизводима рамка.

Проблемна постановка

Нека резултатът на една оценъчна система се формира като претеглена сума на нормализирани индикатори. Един и същ праг може да бъде достигнат чрез различни комбинации от индикаторни стойности, а част от комбинациите могат да бъдат минимални в смисъл, че отпадането на активен индикатор прави прага недостижим. От друга страна, промяната на теглата може да промени не само крайния резултат, но и минималния и типичния брой индикатори, които са достатъчни за покриване на зададеното ниво.

Проблемът следователно има локален и глобален аспект. Локалният аспект изследва поведението на една конкретна система при фиксирани тегла. Глобалният аспект разглежда

множество тегловни структури върху един и същ набор от индикаторни стойности и търси устойчиви структурни характеристики на системата.

Обект, предмет и обхват на изследването

Обект на изследването са линейните многокритериални системи за оценка. Предмет са пространствата от решения, конфигурации и тегловни структури, породени от такива системи при фиксирани и вариращи тегла.

Работата разглежда нормализирани индикатори в интервала [0,1], неотрицателни тегла със сума единица и линейна адитивна оценъчна функция. Експерименталната проверка използва синтетични данни, като е проведен един експеримент на базата на синтетични данни за микроенергийна система. Генераторът допуска различно вероятностно разпределение и параметри за всеки индикатор, тъй като отделните показатели могат да имат различна емпирична форма.

Обхватът включва линейно и смесено целочислено оптимиране, анализ на прагови класове, търсене на недостиг до праг, близо максимални алтернативи, генериране на тегловни структури, Парето анализ, съвместна поява, взаимозаменяемост и по избор изследователска клъстеризация на подпрофили. Ниското, средното и високото оценъчно ниво са предварително дефинирани класове, а не клъстери.

Настоящата разработка има предимно методологичен характер и не претендира да изчерпи всички възможни подходи за анализ на линейни многокритериални системи и на произтичащите от тях пространства от решения и конфигурации. Представеният подход е една възможна аналитична рамка за определен клас практически задачи, при които оценката се формира чрез линейна претеглена функция върху нормализирани индикатори и са зададени прагове и ограничения. Рамката съчетава методи от линейното и смесеното целочислено оптимиране, анализа на чувствителността, генерирането на тегловни структури, Парето анализа, праговото профилиране, анализа на съвместна поява и взаимозаменяемост, както и възпроизводими изчислителни експерименти. Целта е не да се обхванат всички допустими техники, а да се покаже как тези класове методи могат да бъдат интегрирани в един последователен подход за локален и глобален анализ.

Изследователски въпроси

Изследването се ръководи от четири въпроса:

RQ1. При фиксирани тегла как могат да се откриват допустимите, граничните и минималните конфигурации, да се измерва недостигът до зададен праг и да се намират различни алтернативи с близки до максималните резултати?

RQ2. При постоянен набор от данни и постоянен брой индикатори как варирането на теглата променя минималния и типичния брой индикатори, достатъчни за фиксирана оценка, и какъв брой индикатори осигурява реалистичен баланс без излишна сложност?

RQ3. Кои индикатори и комбинации се проявяват устойчиво, кои са взаимозаменяеми и как могат да се опишат типичните профили на предварително определените оценъчни класове? Допълнителна неконтролирана клъстеризация се използва само ако се търси вътрешна подструктура в даден клас, а не за определяне на ниско, средно и високо ниво.

RQ4. Как тези процедури могат да бъдат обединени във възпроизводим Python инструмент, така че експерименталните резултати да могат да бъдат повторени със същите параметри и начални стойности на генераторите?

Цел и задачи на дипломната работа

Целта е да се разработи методология и софтуерен инструмент за анализ на пространствата от решения и конфигурации в линейни многокритериални системи за оценка. За постигането ѝ се дефинира общ математически модел; разработва се генератор на синтетични системи; реализират се локален анализ при фиксирани тегла и глобален структурен анализ при вариращи тегла; разработват се процедури за профилиране, достатъчни комбинации, съвместна поява и взаимозаменяемост; интегрират се в Python инструмент; и се провежда контролирана експериментална проверка.

Методи и очаквани резултати

Използваните методи включват линейно програмиране (ЛП; Linear Programming, LP), смесено целочислено линейно програмиране (СЦЛП; Mixed-Integer Linear Programming, MILP), генериране на извадки от тегловния симплекс, анализ на чувствителността, Парето

анализ, прагово класифициране, анализ на съвместна поява и по избор клъстерен анализ. За локалната задача са добавени процедури за минимална необходима промяна до праг и за извличане на близо максимални наблюдавани алтернативи. За глобалната задача се изчисляват теоретичен минимум, наблюдаван минимум, типичен наблюдаван брой и ефективен брой индикатори.

Очакваният резултат е не просто класиране на алтернативи, а интерпретируемо описание на пространството: минимални носители, гранични решения, профили на оценъчните класове, структурни зависимости между индикатори и устойчивост на тези характеристики спрямо тегловното пространство.

Избраните методи са подбрани спрямо поставените изследователски въпроси и представляват съгласувана комбинация от възможни подходи, а не изчерпателен набор от техники за анализ на многокритериални системи.

Структура на дипломната работа

Глава 1 представя литературния обзор и завършва с изследователски дефицит. Глава 2 формализира собствената изследователска рамка и математическия модел. Глава 3 описва методологията за локален и глобален анализ. Глава 4 представя реалната архитектура и реализация на Python инструмента. Глава 5 прилага разработения скрипт върху единствения експериментален сценарий и представя резултатите, а Глава 6 ги обсъжда спрямо изследователските въпроси и литературата. Заключението обобщава приносите и ограниченията.

Речник на използваната терминология

Термин на български	БГ абр.	Термин на аглийски	EN абр.	Работна дефиниция
Многокритериален анализ на решенията	МАР	Multi-Criteria Decision Analysis	MCDA	Рамка за анализ на решения с множество критерии.
Многоатрибутна теория на полезността	МТП	Multi-Attribute Utility Theory	MAUT	Теория за представяне на предпочитания чрез полезност върху множество атрибути.
Линейно програмиране	ЛП	Linear Programming	LP	Оптимизация с линейна целева функция, линейни ограничения и непрекъснати променливи.
Симплекс метод	-	Simplex method	-	Алгоритъм за ЛП, който преминава между базисни допустими решения до установяване на оптималност.
Преработен симплекс метод	-	Revised simplex method	-	Симплексна реализация, която работи с базисната матрица вместо с пълна таблица.
Двоен симплекс метод	-	Dual simplex method	-	Симплексен вариант, който поддържа двойствена допустимост и възстановява първичната.
Смесено целочислено линейно програмиране	СЦЛП	Mixed-Integer Linear Programming	MILP	Линейна оптимизация с едновременно непрекъснати и целочислени/бинарни променливи.
LP-релаксация / релаксация на целочислеността	-	LP relaxation	LP relaxation	Заместване на ограниченията за целочисленост с непрекъснати граници при запазени линейна целева функция и останали ограничения.
Разклоняване и граници	РГ	Branch-and-Bound	B&B	Търсене в подзадачи с граници от релаксирани задачи.
Разклоняване и отсичане	РО	Branch-and-Cut	B&C	Branch-and-Bound, допълнен с режещи равнини.
Тегловен симплекс	-	Weight simplex	-	Множество от неотрицателни тегловни вектори със сума единица.
Допустимо решение	-	Feasible solution	-	Решение, което удовлетворява всички ограничения.
Допустимо множество	-	Feasible set	-	Множеството от всички допустими решения.
Активен индикатор	-	Active indicator	-	Индикатор, чиято нормализирана стойност преминава зададения праг за структурно участие.
Носител на конфигурация	-	Configuration support	-	Множеството от активни индикатори в дадена конфигурация.
Оценъчен клас	-	Evaluation class	-	Предварително зададен чрез прагове клас на крайния резултат; не е клъстер.
Клъстер	-	Cluster	-	Група, открита от неконтролиран алгоритъм въз основа на сходство.

Термин на български	БГ абр.	Термин на аглийски	EN абр.	Работна дефиниция
Разделяне около медоиди	PM	Partitioning Around Medoids	PAM	Клъстеризация, при която представителите са реални наблюдавани обекти.
Силуетен коефициент	-	Silhouette coefficient	-	Вътрешен показател за компактност и разделеност на клъстерите.
Парето недоминирано решение	-	Pareto-nondominated solution	-	Допустимо решение, за което не съществува друго допустимо решение, което да е не по-лошо по всички цели и строго по-добро поне по една.
Анализ на чувствителността	АЧ	Sensitivity Analysis	SA	Анализ на промяната на изходите при изменение на входните параметри.
Разпределение на Дирихле	-	Dirichlet distribution	-	Разпределение върху симплекс; използва се за генериране на тегловни вектори.
Често множество от елементи	-	Frequent itemset	-	Комбинация от елементи с честота не по-ниска от зададен минимум.
Поддръжка / честота	-	Support	-	Дял наблюдения, в които комбинацията се среща.
Достоверност	-	Confidence	-	Условен дял на успешните наблюдения сред наблюденията, покрити от комбинацията.
Ефективен брой индикатори	-	Effective indicator count	-	Показател $1/\Sigma w_i^2$, който измерва колко балансирано е разпределено теглото между индикаторите.
Анализ на недостига	-	Shortfall analysis	-	Оптимизационно намиране на минимална промяна на индикаторите, необходима за достигане на зададен праг.
Близо максимална алтернатива	-	Near-optimal candidate	-	Наблюдавано допустимо решение в предварително зададена абсолютна близост до най-добрата наблюдавана оценка.
Кардиналност на носителя	-	Support cardinality	-	Броят на активните индикатори в носителя на дадена конфигурация.

Глава 1. Литературен обзор и теоретична рамка

Литературният обзор е организиран около конкретния изследователски проблем: как линейна многокритериална оценъчна система може да бъде анализирана не само като функция, която връща крайна оценка, а като генератор на пространство от допустими решения и конфигурации. Поради това са включени само направления, които имат пряка роля в последващия модел и софтуерна реализация: адитивна полезност, нормализация и тегла, оптимизационно описание на допустимите множества, геометрия и генериране на извадки, чувствителност, Парето анализ, структурно извличане на комбинации, клъстеризация и възпроизводими компютърни експерименти.

1.1. Линейни многокритериални системи и адитивни модели на полезност

Многокритериалният анализ на решенията (MAP; Multi-Criteria Decision Analysis, MCDA) обхваща методи, при които алтернативите се оценяват едновременно по няколко критерия. В многоатрибутната теория на полезността (МТП; Multi-Attribute Utility Theory, MAUT) ключов въпрос е кога общата полезност може да се разложи на функции на отделните атрибути. Fishburn формулира условия за адитивна независимост и показва кога многомерната полезност може да има адитивна форма [6], а по-късно разглежда методи за оценяване на адитивни полезности [8]. Keeney и Raiffa развиват систематична рамка за многокритериални предпочитания и компромиси [14].

В най-простия линеен компенсаторен модел нормализираните индикатори x_i се агрегират чрез претеглена сума $S(x) = \sum_{i=1}^{n} w_i x_i$, където $w_i \geq 0$ и $\sum_{i=1}^{n} w_i = 1$. „Компенсаторен“ означава, че по-ниска стойност по един индикатор може да бъде компенсирана от по-висока стойност по друг. Това свойство е едновременно предимство и ограничение: моделът е прозрачен, но крайният резултат може да скрие различни вътрешни конфигурации.

Съвременните обзори подчертават, че многокритериалният анализ включва както скаларизация и оптимизация, така и подпомагане на избора след получаване на множество решения [4], [18], [25]. За настоящата работа е важна именно структурната гледна точка: не само коя алтернатива има най-висока оценка, а какви конфигурации я пораждат, кои са минимални и доколко се запазват при промяна на теглата.

1.2. Нормализация, теглови структури и композитни индикатори

Комбинирането на индикатори с различни единици и диапазони изисква нормализация. Ръководството на OECD/JRC разглежда нормализацията, теглата, агрегирането и анализа на устойчивостта като взаимно зависими стъпки при конструиране на композитни индикатори [16]. Greco, Ishizaka, Tasiou и Torrisi подчертават, че изборът на тегла и агрегираща функция влияе не само върху числовите стойности, но и върху интерпретацията на композитния индекс [17]. За линейния модел нормализацията до [0,1] има допълнително предимство: позволява всички критерии да участват в една и съща геометрична област и прави тегловите структури сравними.

$$z_i = \frac{(x_i - min_i)}{(max_i - min_i)} \quad (1.2)$$

При критерии от тип „полза“ по-високата нормализирана стойност трябва да означава по-добро представяне. При критерии от тип „разход“ ориентацията се обръща, така че след преобразуването отново по-високата стойност да е предпочитана. Това уеднаквяване е необходимо, за да може линейната оценъчна функция да бъде интерпретирана монотонно. В разработения инструмент се използва min-max нормализация и обръщане на скалата при разходни индикатори; конкретната реализация е описана в глава 4.

Теглата могат да бъдат извеждани чрез експертни оценки, сравнения по двойки, данни или комбинирани процедури. Ayan, Abacıoğlu и Basílio систематизират широк набор от съвременни методи за определяне на тегла [12]. Аналитичният йерархичен процес (АЙП; Analytic Hierarchy Process, AHP) на Saaty е класически пример за получаване на приоритети чрез матрица на сравненията по двойки и главен собствен вектор [9], [24]. Настоящата работа обаче не изследва как теглата са получени; те се приемат като параметри на системата и се анализира какво се случва, когато тези параметри се изменят.

$$W = \{ w \in \mathbb{R}^n : w_i \geq 0, \sum_{i=1}^{n} w_i = 1 \} \quad (1.3)$$

Условието за неотрицателни тегла със сума единица определя единичен симплекс. Това превръща тегловото пространство в ясно определена ограничена геометрична област. Monte Carlo подходът на Mazurek и Strzałka показва как множество теглови вектори може

да се използва за изследване на зависимостта на решенията от теглата [1]. Williams и Cai разглеждат стратегии за генериране на тегла при задачи с претеглена сума и акцентират върху покритието на пространството [5]. За настоящото изследване това е пряко свързано с глобалния модул: теглата не се изменят само едно по едно, а се разглежда извадка от целия симплекс.

Компенсаторността след нормализация и претегляне е полезна, защото прави системата интерпретируема и линейна, но именно тя поражда голям брой различни конфигурации с еднаква или близка оценка. Това е причината анализът на крайния композитен резултат да е недостатъчен за целите на дипломната работа. Необходимо е да се изследва множеството от профили, които достигат зададен праг, както и устойчивостта на това множество при промени в теглата.

1.3. Пространства от решения и конфигурационен прочит

Пространство от решения е множеството от всички вектори на индикаторни стойности, които се разглеждат от модела. Допустимо решение е решение, което удовлетворява всички ограничения; множеството на всички допустими решения образува допустимата област. При линейни ограничения допустимата област е изпъкнал многостен (polyhedron), а когато е ограничена - изпъкнал политоп (polytope) [26].

В тази работа конфигурация означава структурното описание на решение: неговите индикаторни стойности и, когато е необходимо, бинарния модел на активни и неактивни индикатори. Носител на конфигурацията е множеството от активни индикатори. Минимална конфигурация спрямо праг е такава, при която няма по-малък носител, който също да достига прага. Гранична конфигурация е решение в непосредствена близост до границата, определена от прага или ограничение.

Конфигурационният прочит се различава от разглеждането на единична оценка. Две решения могат да имат една и съща стойност $S(x)$, но да използват различни индикаторни профили. Затова работата анализира множество решения, носители и профили, а не само числовия резултат. „Достатъчна комбинация“ се използва в структурен, не в причинно-следствен смисъл: комбинацията е достатъчна, когато наблюдаваното й наличие е свързано с достигане на зададения праг при определения критерий за достоверност.

1.4. Линейно и смесено целочислено оптимиране за допустими и минимални конфигурации

Линейното програмиране (ЛП; Linear Programming, LP) е оптимизационен модел, при който целевата функция и всички ограничения са линейни, а променливите са непрекъснати. Допустимата област на крайномерна ЛП задача е изпъкнал многостен, а ако съществува крайно оптимално решение, поне едно оптимално решение се намира във връх на допустимата област [26]. Тази геометрична връзка е фундаментална за симплекс метода.

Симплекс методът (simplex method) е класически алгоритъм за линейно програмиране, който преминава между базисни допустими решения, съответстващи на върхове на допустимия многостен, докато не установи оптималност. Преработеният симплекс метод (revised simplex method) не съхранява и преобразува пълната симплекс таблица, а работи с базисната матрица и необходимите линейноалгебрични операции. Двойният симплекс метод (dual simplex method) поддържа двойствената допустимост и възстановява първичната допустимост; той е особено удобен при последователно добавяне или изменение на ограничения. Тези алгоритми не трябва да се смесват с понятието „симплекс“ като геометрично множество на теглата.

Когато част от променливите трябва да бъдат цели или бинарни, се получава смесено целочислено линейно програмиране (СЦЛП; Mixed-Integer Linear Programming, MILP) [27], [28]. В настоящата постановка непрекъснатите променливи x_i описват стойностите на индикаторите, а бинарните y_i показват дали индикаторът е активен. Кардиналност на носителя наричаме броя на активните индикатори в него. Така целта $min \sum_{i=1}^{n} \; y_i$ намира конфигурация с минимална кардиналност, т.е. с минимален брой активни индикатори.

Основно понятие при СЦЛП е LP-релаксацията (LP relaxation), наричана тук и релаксация на ограниченията за целочисленост. При нея изискването $y_i \in \{0,1\}$ временно се заменя с $0 < y_i < 1$, като линейната целева функция и останалите ограничения се запазват. Получената задача е обикновена ЛП задача и се решава по-лесно. Решението ѝ може да съдържа дробни стойности и не е непременно допустимо за първоначалната СЦЛП задача, но дава граница за оптималната стойност и подпомага систематичното търсене.

Алгоритмите от типа разклоняване и граници (РГ; Branch-and-Bound, B&B) разделят пространството според целочислените променливи и използват решенията на LP-релаксациите като граници. Разклоняване и отсичане (РО; Branch-and-Cut, B&C) допълва тази логика с режещи равнини, които отстраняват дробни области, без да изключват допустими целочислени решения. Съвременните СЦЛП решаващи модули комбинират тези техники [27], [28].

За задачата на дипломната работа СЦЛП е важно не само като средство за намиране на един оптимум. След намиране на минималната кардиналност могат последователно да се забраняват вече намерените носители и да се изброяват алтернативни минимални конфигурации. Връзката между линейната геометрия, целочислените променливи и изброяването на минимални решения е в основата на локалния анализ [29], [30].

1.5. Геометрия и генериране на извадки от пространства на решения и тегла

Глобалният анализ изисква представително покритие на ограничени многомерни области. Класическите процедури за равномерно генериране на точки в ограничени области и методите на случайно ходене осигуряват теоретична основа за тази задача [31]-[33]. При сложни политопи подходът „удари и продължи“ (Hit-and-Run) е особено важен, защото позволява генериране на точки без директно параметризиране на всяка геометрична граница. В настоящата реализация тегловото пространство е симплекс, което допуска и по-преки генератори.

Експериментите със смеси дават полезна геометрична аналогия, тъй като пропорциите на компонентите са неотрицателни и имат сума единица - същото ограничение, което се налага върху теглата. Cornell разглежда симплексни планове, полиномиални модели и експериментални конструкции за такива пространства [34]. За дипломната работа важна е не конкретната теория на смесите, а идеята, че симплексът е естествена област за систематично разполагане и сравнение на конфигурации с фиксирана сума.

При компютърни експерименти изборът на входни точки влияе върху качеството на заключенията. McKay, Beckman и Conover сравняват стратегии за подбор на входни стойности и формулират подхода на латинския хиперкуб като средство за по-равномерно покритие на многомерни области [35]. В контекста на тегловото пространство това показва

защо една произволна малка извадка може да пропусне важни режими и защо разпределението на теглата трябва да бъде част от експерименталния дизайн.

Monte Carlo генерирането на тегла в многокритериален анализ позволява оценяване на честоти и вероятностни характеристики на решенията при неопределени предпочитания [1]. Williams и Cai разглеждат спецификата на извадките за претеглени суми [5]. В собствената методология са използвани три режима на Дирихле-разпределение: равномерно, балансирано и концентрирано. Те не претендират да представляват реално разпределение на предпочитанията; служат като контролирани сценарии с различна степен на концентрация към центъра или границите на симплекса.

Покритието на пространството трябва да се оценява заедно с възпроизводимостта. Размерът на извадката, параметрите на разпределението и началната стойност на генератора на псевдослучайни числа (seed) са част от дефиницията на експеримента. Това позволява всяка глобална оценка - например честота дадено решение да е първо - да бъде повторена при същите входни условия.

1.6. Анализ на чувствителността и устойчивостта при вариращи тегла

Анализът на чувствителността изследва как измененията на входните параметри се отразяват върху резултатите. В многокритериалните системи чувствителността е особено важна, защото теглата често отразяват предпочитания, оценки или преценки, които не са известни с абсолютна точност. Triantaphyllou и Sánchez предлагат систематичен подход за оценяване на чувствителността при детерминирани многокритериални методи [15], а Antunes и Clímaco разглеждат чувствителността директно в тегловото пространство [22].

Съвременният систематичен обзор на Więckowski и Sałabun показва разнообразието на подходи за чувствителност в MAP [3], а техният по-нов многопараметричен метод разглежда едновременно изменение на повече от един параметър [7]. Библиометричният анализ на Demir, Chatterjee и Pamučar потвърждава нарастващата роля на анализа на чувствителността при оценяване на устойчивостта на решенията [11]. За настоящата работа това мотивира комбинирането на локални отклонения с глобално вариране на теглата.

Интервалите на устойчивост на теглата при модела на претеглената сума дават по-конкретна интерпретация: за дадено решение може да се изследва областта от тегловото пространство, в която то запазва определено свойство [2]. Weber разглежда относителната

устойчивост на многокритериални решения и подчертава необходимостта резултатът да се оценява спрямо допустими изменения на параметрите, а не само в една номинална точка [19].

В дипломната работа се разграничават няколко вида чувствителност. Чувствителността на оценката измерва числовата промяна на композитния резултат. Чувствителността на класа измерва дали решението преминава през оценъчен праг. Чувствителността на ранга проверява промяната на водещото решение. Структурната чувствителност сравнява цели множества - например множеството от решения във високия клас - и поради това е по-близка до основната тема за пространства от конфигурации.

Това разграничение е съществено, защото малка средна промяна на оценката не гарантира структурна устойчивост. Ако много решения са близо до праг, малка промяна може да прехвърли голям брой точки между класовете. Обратно, значими промени в отделни оценки могат да оставят множеството от висок клас почти непроменено. Затова собствената методология използва едновременно средна абсолютна промяна, честота на промяна на класа, коефициент на Жакар за множества и честота на запазване на индикаторни структури.

1.7. Парето анализ, представяне и визуализация на множества от решения

При множество цели не съществува задължително единствено решение, което е най-добро по всички критерии. Парето оптималността описва решенията, които не могат да бъдат подобрени по една цел без влошаване по друга. Съвременните обзори на многокритериалната оптимизация разглеждат доминирането, качествените мерки и представянето на недоминирани множества като основни компоненти на анализа [18], [25].

За практическото подпомагане на решенията самият Парето фронт не е достатъчен, особено при много критерии. Osika и съавтори систематизират методи, които действат „отвъд“ фронта - визуализация, извличане на структура от множества решения, работа с предпочитания и неопределеност [21]. Това е пряко релевантно към дипломната работа, защото целта не е само да се филтрират недоминираните точки, а да се профилира и интерпретира структурата на полученото множество.

Визуализацията на многоцелеви множества е проблем сама по себе си. von Lücken и съавтори разглеждат стратегии за подобряване на визуалното представяне на множества

решения при много цели [20]. pyMCMA предоставя съвременен софтуерен подход за по-равномерно представяне на Парето фронтове [23], а ROSE показва детерминирано изследване на пространството на целите при двуцелеви задачи [13]. Общият извод е, че качеството на представянето влияе върху способността да се разпознават различни режими и компромиси.

В собствената методология Парето анализът има спомагателна, а не единствена роля. Той е необходим, когато конфигурациите се оценяват едновременно по конфликтни свойства - например висока оценка, малък брой активни индикатори, малко отклонение и висока устойчивост. При чисто едномерно ранжиране по линейната оценка Парето филтриране не добавя информация. Следователно използването му се обвързва с конкретно многомерно представяне на качеството на конфигурацията.

1.8. Достатъчни комбинации, съвместна поява и взаимозаменяемост на индикатори

Когато конфигурациите се представят като множества от активни индикатори, възниква естествена връзка с формалния концептуален анализ и извличането на чести множества. Формалният концептуален анализ (ФКА; Formal Concept Analysis, FCA) изгражда връзки между обекти и техните атрибути чрез решетъчна структура [36]. В настоящата работа тази перспектива е важна с идеята, че конфигурациите могат да бъдат изучавани чрез повторяемите отношения между активни свойства, без да се твърди причинност.

Agrawal, Imieliński и Swami формулират класическата задача за извличане на правила за асоциация (association rules) чрез честота на срещане и условна достоверност [37]. Pasquier и съавтори въвеждат затворените чести множества като по-компактно представяне на честата структура [38]. Borgelt систематизира алгоритмите за извличане на чести множества от елементи (ЧМЕ; frequent itemset mining), свойството Apriori, затворените и максималните множества и ефективните структури за търсене [39].

$$support(A) = \frac{|\{t: A \subseteq t\}|}{|T|} \quad (1.5)$$

$$confidence(A \rightarrow H) = \frac{support(A \cap H)}{support(A)} \quad (1.6)$$

За дипломната работа „транзакция“ е бинарният активен профил на едно решение, а целевото събитие H е например принадлежност към висок оценъчен клас. Комбинация A се разглежда като емпирично достатъчна, ако има минимална честота на срещане и висока условна достоверност спрямо H. Допълнително се запазват само подмножествено минимални достатъчни комбинации, за да не се отчита тривиално всяко разширение на вече достатъчно множество.

Съвместната поява и взаимозаменяемостта са различни отношения. Високата съвместна поява означава, че два индикатора често са активни заедно; тя не означава, че могат да се заменят. Взаимозаменяемостта изисква контрафактуална проверка в рамките на модела: при изключване на един индикатор и активиране на друг дали конфигурацията остава допустима и достига целта. В реализацията това отношение е насочено и следователно матрицата на взаимозаменяемост не е задължително симетрична.

1.9. Клъстеризация, профилиране, валидиране и стабилност на клъстерите

Клъстеризацията (clustering) е неконтролирано групиране на обекти по сходство, без предварително зададени етикети [40]. Тя е различна от праговата класификация, при която принадлежността към клас се определя от известни предварително граници. В настоящата задача класовете „ниско“, „средно“ и „високо“ ниво са част от самата оценъчна система и следователно не трябва да бъдат „откривани“ чрез неконтролирана клъстеризация.

Профилирането на оценъчните класове може да се извърши директно чрез средни, медиани и представителни наблюдавани конфигурации. Това отговаря на основната цел: да се сравнят типичните конфигурации, които не покриват минималните изисквания, тези в средния регистър и тези, които покриват високия праг.

Клъстерният анализ остава допустим като вторична изследователска процедура, например ако е необходимо да се провери дали вътре в един предварително определен клас съществуват различни подтипове. За смесени представяния подходящ е коефициентът на Gower [40], а разделянето около медоиди (PAM; Partitioning Around Medoids) използва реални наблюдавани обекти като представители [42]. Качеството може да се оценява със силуетен коефициент (silhouette coefficient), но високата му стойност не заменя съдържателната интерпретация. Стабилността на клъстерите трябва да се проверява при повторни извадки [41].

1.10. Синтетични експерименти и възпроизводими изчислителни изследвания

Синтетичният експеримент позволява да се контролира входното пространство и да се изследват сценарии, които трудно могат да бъдат наблюдавани систематично в реални данни [43], [44]. В многокритериална система това включва броя на индикаторите, техните разпределения, зависимостите между тях, теглата, праговете и ограниченията.

Съществено е всеки индикатор да може да има собствено вероятностно разпределение, защото различните показатели рядко са еднакво разпределени. Затова генераторът трябва да позволява например равномерно (uniform), бета (beta), ограничено нормално (truncated normal), триъгълно (triangular) или константно разпределение с отделни параметри за всеки индикатор. Общите режими могат да се използват за бързи сценарии, но не трябва да бъдат единствената възможност.

Възпроизводимото изчислително изследване изисква записване на параметрите, версиите на средата и началните стойности на генераторите на псевдослучайни числа [45]-[47]. Графиките и таблиците следва да се генерират от същия изпълним процес, който произвежда числовите резултати, за да не възниква разминаване между анализ и представяне.

1.11. Синтез на литературата, установени дефицити и място на настоящата работа

Литературата предлага добре развити самостоятелни направления за адитивни многокритериални модели, линейно и смесено целочислено оптимиране, тегловна чувствителност, генериране на извадки, Парето анализ, структурни комбинации и профилиране. По-слабо застъпено е тяхното обединяване около един и същ обект: пространството от конфигурации на линейна оценъчна система.

Първият дефицит е свързан с локалния прочит. Обичайното изчисляване на крайна оценка не отговаря непосредствено на три практически въпроса: кои минимални конфигурации покриват прага, каква е най-малката промяна за решение под прага и какви различни наблюдавани решения са близки до най-добрия резултат.

Вторият дефицит е глобален и структурен. Анализът при вариращи тегла често се фокусира върху промени в ранговете или класовете [2], [3], [7], [19], [22]. За настоящата задача е необходимо допълнително да се оцени колко индикатора са теоретично достатъчни, колко са достатъчни в наблюдаваните данни, колко обичайно са нужни при успешните конфигурации и доколко тегловната структура е концентрирана или балансирана.

Третият дефицит е методологичен: праговите оценъчни класове и клъстерите трябва ясно да се разграничат. Ниското, средното и високото ниво са зададени от правилата на оценяване; неконтролираната клъстеризация има смисъл само като допълнителен инструмент за вътрешна подструктура, не като заместител на тези класове.

Настоящата работа адресира дефицитите чрез единна рамка: локален анализ на конкретна система при фиксирани тегла; глобален структурен анализ при вариращи тегла и постоянен набор от данни; профилиране по предварително зададени класове; анализ на достатъчни комбинации и взаимозаменяемост; и възпроизводима софтуерна реализация. Приносът е в интегрирането и операционализирането на известни методи, а не в претенция за нови базови алгоритми.

Направеният обзор показва, че линейните многокритериални модели, анализът на чувствителността, генерирането на теглови структури, Парето анализът и структурното профилиране са добре развити като отделни направления. Следващата глава формулира математическия модел, чрез който тези направления се свързват с конкретните локални и глобални изследователски въпроси.

Глава 2. Изследователска рамка и математически модел

Изследователската рамка произтича непосредствено от дефицитите, установени в литературния обзор. Моделът трябва едновременно да описва една конкретна линейна оценъчна система, да допуска структурни ограничения върху решенията и да позволява вариране на теглата в глобален анализ. Поради това се въвеждат отделно пространството на индикаторните стойности, тегловото пространство, оценъчните прагове и бинарното представяне на активността.

2.1. Изследователска логика и въпроси

Изследователската логика следва две свързани, но различни задачи. При локалния анализ моделът на конкретната оценъчна система, включително теглата, е фиксиран, а се изследват възможните стойности и конфигурации на индикаторите. При глобалния анализ наборът X и броят на индикаторите остават фиксирани, а се варират само тегловните вектори w.

Тази постановка свързва RQ1 с пространството на решенията на една система и RQ2 със структурните свойства на клас от тегловни системи върху едни и същи данни. RQ3 използва предварително зададените оценъчни класове за профилиране и структурни комбинации, а RQ4 се реализира чрез единен софтуерен поток от входните параметри към резултатни таблици и визуализации.

2.2. Формално описание на индикаторите

Нека n е броят на индикаторите и $x = (x_1, \ldots, x_n)^T$ е векторът на нормализирани стойности. След ориентиране на всички показатели в посока „по-висока стойност е по-добра“ се приема $x_i \in [0,1]$. При разходен индикатор нормализацията обръща посоката, така че стойност 1 отново означава по-добро представяне.

Всеки индикатор има име, тип „полза“ или „разход“, по избор референтни сурови граници и праг за активност a_i . Индикаторът е активен в структурния смисъл, когато $x_i > a_i$. Бинарната маска на активност $b_i = 1\{x_i > a_i\}$ се използва при анализа на носители, минимални конфигурации и съвместна поява.

Синтетичният генератор допуска отделна спецификация на вероятностното разпределение за всеки индикатор. Това позволява x_i да бъде генериран например от различно равномерно, бета, ограничено нормално, триъгълно или константно разпределение. Така различната статистическа природа на показателите се представя експлицитно, вместо всички колони да се принуждават към една обща форма.

2.3. Формално описание на теглата

Тегловният вектор е $w = (w_1, \ldots, w_n)^T$, където $w_i > 0$ и $\sum_{i=1}^{n} w_i = 1$ Допустимото тегловно пространство е стандартният (n−1)-мерен симплекс е Δ^{n-1}. Тук „симплекс“ означава геометричното множество на теглата и не означава симплекс алгоритъма за линейно програмиране. Допустимото тегловно пространство е стандартният (n−1)-мерен симплекс

При локалния анализ w е фиксиран и представлява конкретната работеща индикаторна система. При глобалния анализ се генерира множество $W = \{w^{(1)}, \ldots, w^{(m)}\} \subset \Delta^{n-1}$, докато X и n се запазват непроменени. По този начин ефектите се отнасят към тегловната структура, а не към едновременно изменение на данни и тегла.

2.4. Линейна оценъчна функция

Крайната оценка на конфигурация x при тегла w е $S_w(x) = w^\tau x = \sum_{i=1}^{n} w_i x_i$. Понеже $x_i \epsilon [0,1]$, $w_i \geq 0$ и $\sum_{i=1}^{n} w_i = 1$, следва $S_w(x) \epsilon [0,1]$. Функцията е монотонна по всеки benefit-ориентиран нормализиран индикатор: увеличаването на x_i не може да намали оценката.

Линейността позволява задачите „достига ли се прагът?“, „каква минимална промяна е необходима?“ и „колко активни индикатора са необходими?“ да се формулират като линейни или смесени целочислени линейни задачи.

2.5. Оценъчни прагове и класове резултати

Нека $0 \leq \tau_1 < \ldots < \tau_q \leq 1$ са праговете на оценъчната схема. Те разделят интервала [0,1] на $q + 1$ предварително дефинирани оценъчни класа. В експерименталния сценарий $\tau_1 = 0.40$ и $\tau_2 = 0.70$ определят класовете low, medium и high.

Тези класове са правило на оценъчната система, а не резултат от клъстеризация. Следователно профилирането им е контролирана класификационна задача. Неконтролирана клъстеризация може да се използва само допълнително, ако се търсят подтипове вътре в някой от класовете.

2.6. Ограничения и допустими области

Допустимата област $F \subseteq [0,1]^n$ се задава чрез линейни ограничения. Те могат да включват минимални или максимални стойности, линейни зависимости, бюджетни условия, задължителни и изключени индикатори и максимален брой активни индикатори.

Когато ограничението се отнася до това дали индикатор участва, се въвеждат бинарни променливи $y_i \epsilon \{0,1\}$. Връзките $x_i \leq y_i$ и $x_i \geq \varepsilon_i y_i$ свързват непрекъснатата стойност с бинарния статут: $y_i = 0$ налага $x_i = 0$, а $y_i = 1$ изисква x_i да е поне ε_i . Така структурните условия се формулират като СЦЛП.

2.7. Представяне на решения, конфигурации и оценъчни системи

Решение е конкретен вектор x от индикаторни стойности. Конфигурация е този стойностен профил заедно с бинарния модел на активните индикатори. Носителят supp(x) е множеството от активните индикатори. Минимална конфигурация за праг τ няма собствен подносител, който също да достига τ; граничната конфигурация лежи върху или непосредствено над съответната прагова граница.

Оценъчна система се определя от множеството индикатори, ориентациите и нормализациите им, теглата, праговете и структурните ограничения. Така локалният анализ работи с една система, а глобалният - с множество системи, които се различават по тегловния вектор.

2.8. Разграничение между локален и глобален анализ

Локалният анализ фиксира теглата и изследва как работи конкретната индикаторна система. Той търси: (1) варианти за покриване на минималното условие; (2) минималната необходима промяна за конфигурации, които не достигат прага; (3) различни алтернативи, които постигат близки до максималните резултати. С други думи, променлива е конфигурацията x, а w е постоянен.

Глобалният анализ фиксира набора X и броя n, но променя w в тегловния симплекс. Целта е структурна: да се оцени минималният брой индикатори, който е достатъчен при фиксиран праг, както и реалистичният брой индикатори, който обичайно участва в успешните конфигурации и не допуска прекомерна концентрация на теглото. Затова се използват едновременно кардинални и балансови показатели.

2.9. Допускания и граници на модела

Моделът приема линейна адитивна функция, точни нормализирани стойности и неотрицателни тегла със сума единица. Синтетичните данни не доказват външна валидност за конкретна предметна област; те служат за контролирана проверка на методологията. Активността зависи от зададен праг и е аналитична конструкция, а не причинна характеристика.

Типичният брой индикатори в глобалния анализ е емпиричен показател за конкретния набор X и целевия праг, а не универсална препоръка. Ефективният брой индикатори $\frac{1}{\sum_{i=1}^{n} {w_i}^2}$ измерва баланс на теглата, но също не трябва да се интерпретира като единствен нормативен критерий за дизайн на система.

Глава 3. Методология за анализ на пространствата от решения и конфигурации

Методологията превръща формалния модел от глава 2 в последователен изследователски процес. Основният принцип е една и съща конфигурация да бъде наблюдавана от няколко гледни точки: като числов профил, като бинарен носител, като елемент от оценъчен клас и като кандидат за минималност; само при активиран допълнителен изследователски режим тя може да се разглежда и като член на клъстер. Локалният и глобалният анализ споделят еднаква дефиниция на модела и се различават по това дали тегловният вектор е фиксиран или се генерира множество от тегловни системи.

3.1. Общ изследователски процес

1. Изследователският процес започва с дефиниране на индикаторите, нормализацията, теглата, праговете и ограниченията. След това се получава или генерира наборът X и се проверява допустимостта му.

2. Локалният етап използва фиксираните тегла: оценява и класифицира решенията; намира минимални и гранични конфигурации; изчислява недостига до целевия праг; извлича близо максимални наблюдавани алтернативи; и профилира предварително зададените оценъчни класове.

3. Глобалният етап държи X и n постоянни и генерира тегловни вектори върху симплекса. За всяка тегловна система се изчисляват оценки, класове, победители и структурни показатели за необходимия брой индикатори.

4. Следват анализ на чувствителността, Парето филтриране, съвместна поява и взаимозаменяемост. Клъстеризация се изпълнява само ако изследователят изрично активира изследователски режим за вътрешни подтипове; тя не определя оценъчните класове.

5. Всички параметри, начални стойности на генераторите на псевдослучайни числа, таблици и графики се съхраняват така, че един и същ сценарий да може да бъде изпълнен повторно.

3.2. Генериране на синтетични данни и сценарии

Генерирането на синтетични стойности има два режима. Общите режими създават цели матрици със сходен тип поведение - равномерни, ниски, високи, смесени, групирани или корелирани профили. По-гъвкавият режим задава отделно разпределение за всеки индикатор.

Спецификацията по индикатор допуска uniform, beta, truncated_normal, triangular и constant. Всеки тип има собствени параметри, а резултатът се ограничава до [0,1]. Така например един индикатор може да бъде концентриран около ниски стойности, друг - около високи, а трети - приблизително симетричен.

Теглата се генерират върху симплекса чрез разпределение на Дирихле. Различни параметри α позволяват да се моделират по-балансирани или по-концентрирани тегловни структури. Случайността се контролира с фиксирана seed стойност.

3.3. Локален анализ при фиксирани тегла

Локалният анализ разглежда конкретната система при фиксиран w. Първо всички наблюдавани решения се оценяват, проверяват за допустимост и се разпределят в предварително зададените оценъчни класове. Това дава директен отговор кои конфигурации са под минималните условия, кои са в междинния регистър и кои достигат високото ниво.

За въпроса „какви са вариантите да покрием условията?“ се решава СЦЛП задача min $\sum_{i=1}^{n} y_i$ при $S_w(x) \geq \tau$ и структурните ограничения. След намиране на минималния брой активни индикатори k се налага $\sum_{i=1}^{n} y_i = k$ и се минимизира $\sum_{i=1}^{n} x_i$. Последователно се забраняват вече намерените носители, за да се изброят алтернативни минимални конфигурации.

За въпроса „какво не достига?“ се решава задача за минимална обща положителна промяна $\Delta \geq 0$, така че $x + \Delta$ да стане допустимо и да достигне τ. Полученият анализ на недостига посочва кои индикатори трябва да се увеличат в нормализираното пространство, в което по-високата стойност означава по-добро представяне, и с колко.

За въпроса „какви са алтернативите за близо максимален резултат?“ първо се определя най-добрата наблюдавана допустима оценка, след което се извличат всички решения в предварително зададен абсолютен толеранс от нея. Отделно се решава

оптимизационна задача за максимално постижимата оценка при структурните ограничения, което различава наблюдавания максимум от теоретично достижимия.

3.4. Глобален анализ при вариращи тегла

Глобалният анализ запазва X и n и варира само тегловния вектор w. Това позволява резултатите да се интерпретират като структурна чувствителност на индикаторната система, а не като смесен ефект от промени в данните и теглата.

За всяка тегловна система се изчислява теоретичен минимален брой индикатори: теглата се подреждат низходящо и се намира най-малкият k, за който сумата на k-те най-големи тегла достига целевия праг, при идеализираното допускане $x_i = 1$. Това е долна структурна граница, а не непременно достижима конфигурация в наблюдаваните данни.

Наблюдаваният минимален брой се получава сред реално успешните конфигурации. За всяка такава конфигурация приносите $w_i\ x_i$ се подреждат низходящо и се определя най-малкият брой, чиято натрупана сума достига прага; минимумът между успешните решения показва най-компактната наблюдавана реализация. Медианата на тези индивидуални бройки се използва като типичен или реалистичен наблюдаван брой индикатори.

Балансът на теглата се характеризира чрез ефективен брой индикатори $N_{eff} = \frac{1}{\sum_{i=1}^{n} {w_i}^2}$. При равни тегла $N_{eff} = n$, а при силна концентрация към един показател N_{eff} се доближава до 1. Съвместното разглеждане на минималния, типичния и ефективния брой позволява да се прецени дали системата постига целевото ниво с прекалено малко доминиращи индикатори или с по-балансирано участие.

Допълнително се изчисляват вероятности за оценъчните класове, честоти на победителите, промяна на класовете спрямо базовата система и устойчивост на силно проявените индикатори.

3.5. Метрики и Парето анализ

Разстоянието между конфигурации зависи от представянето. За непрекъснати профили могат да се използват евклидово или косинусно разстояние, за бинарни маски - Хеминг или Жакар, а за смесени данни - коефициентът на Gower [40]. В основния експеримент тези метрики не се използват за дефиниране на оценъчните класове.

Парето анализът отделя решения, които не са доминирани едновременно по разглежданите измерения, ориентирани така, че по-високата стойност да е по-добра. Той допълва претеглената сума, защото показва компромисни конфигурации, които могат да бъдат загубени при едно конкретно тегловно скаларизиране [18], [21], [25]. В собствената методология Парето множеството служи за структурно сравнение и за търсене на алтернативи, а не заменя основната оценъчна функция.

3.6. Анализ на чувствителността и устойчивостта

Анализът на чувствителността (АЧ; Sensitivity Analysis, SA) измерва как изменението на индикаторни стойности, тегла и прагове променя резултатите [3], [7], [11], [22]. При локалната задача е особено важен недостигът до праг и промяната на оценъчния клас при изменение на x.

При глобалната задача устойчивостта се оценява по няколко начина: запазване на класа, сходство между множествата от решения във високия клас, честота на победителя, стабилност на силно проявените индикатори и разпределение на структурните показатели за броя на индикаторите. Така чувствителността не се свежда до една числова промяна на крайната оценка.

3.7. Клъстеризация и профилиране

Основното профилиране е по предварително зададените оценъчни класове. За всеки клас се изчисляват размер, среден и медианен профил и представителна наблюдавана конфигурация. Представителят е реално наблюдение, най-близко до центъра на класа, което улеснява съдържателната интерпретация.

Неконтролираната клъстеризация не се използва за възстановяване на low/medium/high. Тя е опционален изследователски режим за случаи, в които се търсят вътрешни подтипове в дадена група или в цялото пространство. Ако бъде активирана, инструментът поддържа Gower-разстояние, k-medoids и избор на k по силует, но резултатът се интерпретира отделно от оценъчните класове [40]-[42].

3.8. Честота, съвместна поява и взаимозаменяемост

От бинарната матрица на активност се изчисляват едномерни честоти и матрици на съвместна поява. За двойка индикатори се определят честота на съвместна активност, условна достоверност и повдигане (lift) спрямо независимото им срещане. Тези показатели се използват като описателни, а не причинни характеристики.

Достатъчните комбинации се търсят сред множества с размер до предварително зададен максимум. За всяка комбинация се проверяват минимална честота и условна достоверност за достигане на целевия клас. След това се отстраняват надмножества на вече достатъчни по-малки комбинации. По този начин резултатът е по-компактен и насочен към минимални емпирични структури.

Взаимозаменяемостта се оценява чрез насочен тест. За всяко решение и двойка индикатори $i \to j$ се поставя i в неактивно състояние и j в максимално активно състояние, след което се проверява допустимостта и достигането на целта. Делът успешни замени формира елемент от матрицата. Тъй като замяната $i \to j$ и $j \to i$ може да има различен резултат, матрицата не се симетризира.

3.9. Критерии за валидиране и интерпретация

Валидирането се извършва на няколко равнища. Математическата коректност се проверява чрез тестове на оценъчната функция, ограниченията, минималната кардиналност, недостига до праг, Парето доминирането и структурните показатели. Покритието на тегловното пространство се оценява чрез размер и режим на извадката.

Оценъчните класове се валидират спрямо праговата схема, а не чрез вътрешни клъстерни индекси. Силуетът има роля само ако е активирана опционална клъстеризация. Достатъчните комбинации се интерпретират заедно с поддръжката и достоверността им, а показателите за глобален брой индикатори се разглеждат съвместно, защото нито теоретичният минимум, нито N_{eff} сами по себе си са достатъчни за препоръка.

3.10. Мащабируемост и възпроизводимост

Изчислителната сложност на отделните компоненти нараства различно. Матричното преоценяване при много тегла се мащабира приблизително линейно по броя алтернативи и тегловни системи. Изчисляването на матрица от разстояния и клъстеризацията изискват

двойкови сравнения и нарастват квадратично по броя обекти. Изброяването на всички минимални бинарни носители може да стане комбинаторно трудно с увеличаване на броя индикатори. Поради това инструментът позволява ограничение на броя върнати оптимизационни решения и използване на извадки.

Възпроизводимостта следва препоръките за изчислителни изследвания: параметрите се записват, случайността се контролира чрез начални стойности, резултатите се експортират в машинно четими формати и графиките се генерират програмно [45]-[47].

Глава 4. Проектиране и реализация на софтуерния инструмент

Софтуерният инструмент е реализиран като Python пакет mcda_space. Основният поток следва директно разграничението между локален анализ на конкретна система и глобален структурен анализ при вариращи тегла. Праговите класове са основният механизъм за профилиране, а неконтролираната клъстеризация е изключена по подразбиране и остава само като опционална изследователска процедура.

4.1. Функционални и нефункционални изисквания

Функционалните изисквания са: дефиниране и валидиране на индикатори, тегла, прагове и ограничения; нормализация; генериране на синтетични данни с индивидуални разпределения по индикатор; локално оценяване и прагово класифициране; СЦЛП търсене и изброяване на минимални конфигурации; анализ на недостига до праг; близо максимални алтернативи; глобално вариране само на теглата; структурни показатели за минимален, типичен и ефективен брой индикатори; Парето анализ, съвместна поява, взаимозаменяемост, профили и визуализации.

Нефункционалните изисквания включват възпроизводимост, проверимост, разширяемост и ясно разграничаване на методологичните роли на отделните процедури. Всички експериментални графики се генерират програмно от същото изпълнение, което произвежда таблиците.

4.2. Архитектура на инструмента

Таблица 1: Архитектура на приложението

Модул	**Основни обекти**	**Роля**
models.py	IndicatorSpec, ThresholdScheme, LinearConstraintSpec, LinearMCDAModel	Централен модел, оценъчни класове, активност и допустимост.
normalization.py	Normalizer	Min-max преобразуване и обръщане на разходни индикатори.
generators.py	IndicatorDistributionSpec, SyntheticDataGenerator, WeightGenerator	Индивидуални разпределения по индикатор и тегловни извадки.
local_analysis.py	LocalAnalyzer, MILPConfiguration, ImprovementPlan	Минимални конфигурации, недостиг до праг, близо максимални решения.
global_analysis.py	GlobalAnalyzer, GlobalAnalysisResult	Вариращи тегла при фиксирано X; структурен брой и баланс на индикаторите.
analytics.py	ParetoAnalyzer, ProfileAnalyzer, ConfigurationPatterns; опционално KMedoids	Парето, профили на класове, комбинации; клъстеризация само по избор.
sensitivity.py	SensitivityAnalyzer	Чувствителност на индикатори, тегла, прагове и структура.

Модул	Основни обекти	Роля
pipeline.py	AnalysisSettings, AnalysisPipeline	Интегриран локален/глобален работен поток.
visualization.py	Visualizer	Програмно генериране на научни графики.
reporting.py	export_results	CSV/JSON/NPY изход и manifest.
io.py	входни функции	JSON конфигурации и CSV/Excel данни.
experiments.py	експериментални помощни функции	Контролирано изпълнение и сравнение на сценарии.

Централният архитектурен обект е LinearMCDAModel. Останалите анализатори получават този модел като зависимост, което гарантира единно използване на теглата, праговете, имената на индикаторите и ограниченията. AnalysisPipeline свързва отделните анализатори, но не дублира техните алгоритми. Това позволява отделна функция да бъде извикана самостоятелно при тест или специализиран сценарий.

4.3. Входни параметри и потребителски сценарии

Индикаторът се описва чрез IndicatorSpec: име, тип benefit/cost, по избор сурови референтни граници, праг за активност и флагове required/excluded. ThresholdScheme задава подредени прагове и етикети на оценъчните класове. LinearConstraintSpec представя допълнителни линейни ограничения, а LinearMCDAModel обединява индикаторите, теглата, праговете и ограниченията.

Командният интерфейс run_analysis.py приема JSON конфигурация и CSV/XLSX таблица. Потребителят може да зададе целева оценка, размер и режим на тегловната извадка, толеранс за близо максимални решения и дали да бъде активирана опционална клъстеризация. Основният сценарий на дипломната работа не активира неконтролирана клъстеризация.

4.4. Модул за генериране на данни

SyntheticDataGenerator поддържа два начина на работа. Първият запазва общите режими uniform, high, low, mixed, clustered и correlated за бързи синтетични сценарии. Вторият приема списък от IndicatorDistributionSpec и генерира всеки индикатор от собствено разпределение. Поддържат се uniform, beta, truncated_normal, triangular и constant с отделни параметри за всяка колона.

WeightGenerator генерира равни, Дирихле, балансирани и концентрирани тегловни вектори. Всички изходи са неотрицателни и се нормализират до сума единица.

4.5. Реализация на локалния модул

LocalAnalyzer.analyze_candidates изчислява оценка, оценъчен клас, допустимост и брой активни индикатори. configurations_by_class връща именно предварително зададените класове; в кода изрично е отбелязано, че това е класификация, а не клъстеризация.

Минималните конфигурации се решават чрез scipy.optimize.milp от SciPy [49]. Функцията подава СЦЛП модела към решаващия модул HiGHS. Векторът на променливите комбинира непрекъснатите x_i и бинарните y_i; ограниченията $x_i \leq y_i$ и $x_i \geq \varepsilon_i \, y_i$ свързват стойността и активността. Първата цел $min \sum_{i=1}^{n} \; y_i$ намира минималния брой активни индикатори, а след фиксиране на тази кардиналност целта $min \sum_{i=1}^{n} \; x_i$ намира граничен представител на конкретния носител.

HiGHS решава СЦЛП задачата чрез процедура за смесено целочислено оптимиране от типа разклоняване и отсичане (Branch-and-Cut). В хода на търсенето се решават LP-релаксации, при които изискванията за целочисленост временно се заменят с непрекъснати граници при запазени линейна целева функция и останали ограничения. Кодът не задава експлицитно вътрешния алгоритъм на HiGHS за решаване на тези линейни подзадачи; затова не се твърди, че конкретното изпълнение извиква пряко двоен симплекс метод. Симплексните методи са разгледани като теоретична основа на линейното програмиране, а конкретният избор на алгоритъм и решаването на подзадачите са делегирани на HiGHS.

Функцията enumerate_minimum_cardinality реализира изброяването на алтернативни минимални носители около решаващия модул: след всяко решение се добавя ограничение, което забранява точно намерения бинарен носител, и задачата се решава отново. Така изброяването е логика на разработения инструмент, а не специална команда на HiGHS.

За анализа на недостига improvement_plan минимизира общата положителна промяна на нормализираните benefit-ориентирани индикатори, необходима за достигане на целевия праг. shortfall_analysis прилага процедурата към всички допустими наблюдавани конфигурации под прага. near_optimal_candidates извлича решенията в зададен абсолютен толеранс от най-добрата наблюдавана оценка, а maximum_achievable_configuration решава отделна задача за максимално постижимия резултат.

4.6. Реализация на глобалния модул

GlobalAnalyzer преизчислява една и съща матрица X за всички тегловни вектори W. Нито стойностите, нито броят на индикаторите се променят между системите. За всяко наблюдение се изчисляват разпределение на оценките и класовете, а за всяка тегловна система - победител, устойчивост и структурни характеристики.

indicator_count_structure реализира основната структурна цел на глобалния анализ. theoretical_min_indicators е долна граница, получена от натрупаната сума на най-големите тегла. observed_min_indicators е най-малкият брой действителни приноси $w_i\ x_i$, достатъчен за прага сред успешните наблюдавани решения. observed_median_indicators е медианният необходим брой сред успешните решения и се интерпретира като типичен наблюдаван размер, а observed_q75_indicators дава по-консервативна характеристика.

Ефективният брой индикатори се изчислява като $\frac{1}{\sum_{i=1}^{n} {w_i}^2}$ и служи като диагностичен показател за баланса на тегловната структура. Допълнително се записват максималното единично тегло, HHI-подобна концентрация и дял на успешните наблюдения. Обобщението по тегловни системи включва минимум, първи квартил, медиана, трети квартил и максимум.

Функцията cluster_systems е запазена единствено за опционално изследователско групиране на тегловни системи и не участва в основния експеримент. Основният глобален извод се основава на структурните показатели, а не на предварително зададен брой клъстери.

4.7. Реализация на аналитичния модул

ProfileAnalyzer.class_profiles описва предварително зададените оценъчни класове чрез средни стойности, медиани и представителни реални наблюдения. Това е основният профилиращ механизъм. KMedoids и силуетният коефициент са запазени като опционални средства за вътрешна подструктура и не се изпълняват по подразбиране.

ParetoAnalyzer.mask извършва проверка за доминиране. DistanceMetrics поддържа euclidean, cosine, hamming, jaccard и gower. ConfigurationPatterns.co_occurrence изчислява съвместна поява, sufficient_itemsets търси достатъчни комбинации по поддръжка и достоверност, а substitutability проверява насочена взаимозаменяемост при достигане на целевия праг.

4.8. Визуализации и отчети

Visualizer използва Matplotlib [48]. Основното изпълнение генерира разпределение на оценките, вероятност за първо място, профили по предварително зададен оценъчен клас, топлинна карта на съвместната поява, честота на глобално силните индикатори и графика на структурния брой индикатори. Графиката на профилите вече визуализира low/medium/high, а не клъстери.

В Глава 5 са включени само изображения, генерирани от marin_microgrid_test.py след преработката. Няма ръчно конструирани експериментални графики.

4.9. Съхранение и възпроизводимост на експериментите

reporting.py записва табличните резултати като CSV, речници и скаларни стойности като JSON и масиви като NPY, заедно с manifest.json. AnalysisSettings централизира целевия праг, тегловните извадки, толеранса за близо максимални решения и параметрите на структурните анализи.

Опциите exploratory_clustering и exploratory_global_system_clustering са False по подразбиране. Така възпроизводимият основен поток съответства на методологията: праговите класове се профилират директно, а неконтролираната клъстеризация се активира само при допълнителен изследователски въпрос.

4.10. Шаблон за анализ на потребителски данни

Потребителският вход се състои от конфигурационен JSON и табличен файл. JSON описва имената и типовете индикатори, теглата и праговете; по избор включва сурови референтни граници и ограничения. Таблицата трябва да съдържа колони със съответните имена. При липса на референтни граници min-max нормализацията използва текущата извадка, което трябва да се отчита при сравнение между отделни набори данни.

Шаблонът показва приложимостта на инструмента извън синтетичния сценарий, но не разширява емпиричния обхват на дипломната работа.

Шаблонът е показан в Приложение 4.

4.11. Тестване и техническа верификация

Проектът съдържа автоматични тестове за моделите, генераторите, локалния анализ, глобалния анализ и аналитичните процедури. След преработката тестовият набор съдържа 14 теста и всички преминават успешно. Новите тестове проверяват индивидуалните разпределения по индикатор, плана за минимална промяна до праг, структурните показатели на глобалния анализ и профилирането на предварително зададените класове.

Експерименталният сценарий е изпълнен с Python 3.13.5, NumPy 2.3.5, pandas 2.2.3, SciPy 1.17.0, Matplotlib 3.10.8 и openpyxl 3.1.5. Проектът декларира минимално Python 3.11. Основната оптимизация използва scipy.optimize.milp, което в тази среда е обвивка към HiGHS.

Глава 5. Експериментални изследвания и резултати

Постановка на експерименталната задача

Разглежда се синтетична микроенергийна система, в която всяко наблюдение представлява възможна конфигурация на работа, описана чрез пет индикатора: Price, Losses, BatteryWear, CO2Saved и Flexibility. Първите три индикатора са от тип „разход“, а последните два - от тип „полза“. След нормализация всички показатели се представят в общия интервал [0,1] и се ориентират така, че по-висока нормализирана стойност означава по-добро представяне. По този начин всяка конфигурация може да бъде оценена чрез една и съща линейна многокритериална функция. Тези индикатори са със синтетичен характер с предметна интерпретация, а не реално измерени физически величини. Това означава, че чисто семантично могат да бъдат натоварени с различн смисъл. Например BatteryWear може да бъде процент деградация, цикли или парична амортизация, докато Flexibility може да бъде както резервни мощности на енергийната система, така и процент от общия капацитет мощности на системата или индекс, който отразява натоварването.

Така, всяка алтернатива представлява синтетично генериран режим на работа на микроенергийната система и се описва чрез пет сурови показателя. Price характеризира ценовия аспект на режима, Losses - свързаните с него загуби, BatteryWear - износването на батерията, CO2Saved - спестените емисии, а Flexibility - гъвкавостта на режима. Показателите имат илюстративна предметна интерпретация и не са зададени във физически мерни единици, тъй като сценарият не моделира конкретна реална инфраструктура. След нормализацията техните стойности вече се интерпретират като безразмерни оценки на представянето в интервала [0,1], като стойност 1 винаги означава по-благоприятно представяне по съответния критерий.

Експерименталната задача има два взаимно допълващи се аспекта. При локалния анализ се разглежда конкретна индикаторна система с фиксирани базови тегла. Целта е да се установи кои конфигурации достигат зададения висок праг 0.70, какъв е минималният брой активни индикатори, необходим за достигането му, какво не достига на конфигурациите под прага и кои от наблюдаваните решения са близки до максимално постигнатия резултат. Така локалният анализ отговаря на практическия въпрос как работи

конкретната оценъчна система и какви алтернативни конфигурации могат да удовлетворят нейните условия.

При глобалния анализ наборът от 100 наблюдавани конфигурации и броят на индикаторите се запазват постоянни, а се изменя единствено тегловният вектор. Целта е да се изследва структурата на самата индикаторна система: как варирането на теглата влияе върху минималния брой водещи индикаторни приноси, достатъчни за достигане на фиксирания праг в наблюдавана успешна конфигурация, какъв брой индикаторни приноси обичайно участва в успешните конфигурации и доколко системата е балансирана или доминирана от малък брой показатели. Поради това глобалният анализ не се използва за оценка на отделна конфигурация, а за изследване на устойчивостта и структурните характеристики на оценъчната система при различни допустими тегловни режими.

Така поставеният експеримент не цели моделиране на конкретна реална микроенергийна инфраструктура, а контролирана проверка на разработената методология върху единствен синтетичен сценарий. Чрез него се демонстрира как една и съща линейна многокритериална система може да бъде анализирана едновременно на равнище конкретни конфигурации и на равнище структура на индикаторната система.

Сценарият служи като контролирана задача за проверка на методологията, а не като модел на конкретна реална инфраструктура.

5.1. Дизайн на експериментите

Таблица 2: Дизайн на експеримента

Параметър	**Стойност**	**Роля**
Брой алтернативи	100	Синтетично генерирани със seed=101
Брой индикатори	5	Price, Losses, BatteryWear, CO2Saved, Flexibility
Базови тегла	0.25; 0.15; 0.20; 0.20; 0.20	Сума 1
Оценъчни прагове	0.40; 0.70	low / medium / high; предварително зададени класове
Целева оценка	0.70	Минимални конфигурации, недостиг и структурен глобален анализ
Праг за локална активност	0.10	IndicatorSpec.active_threshold
Праг за съвместна поява	0.60	Отделен от локалната активност
Праг за глобално силен индикатор	0.80	stable_indicator_frequency
Тегловна извадка	1000 на режим	Дирихле α=1; α=5; α=0.35
Близо максимални решения	толеранс 0.03	До 0.03 под най-добрата наблюдавана оценка
Неконтролирана клъстеризация	изключена	Не определя low/medium/high

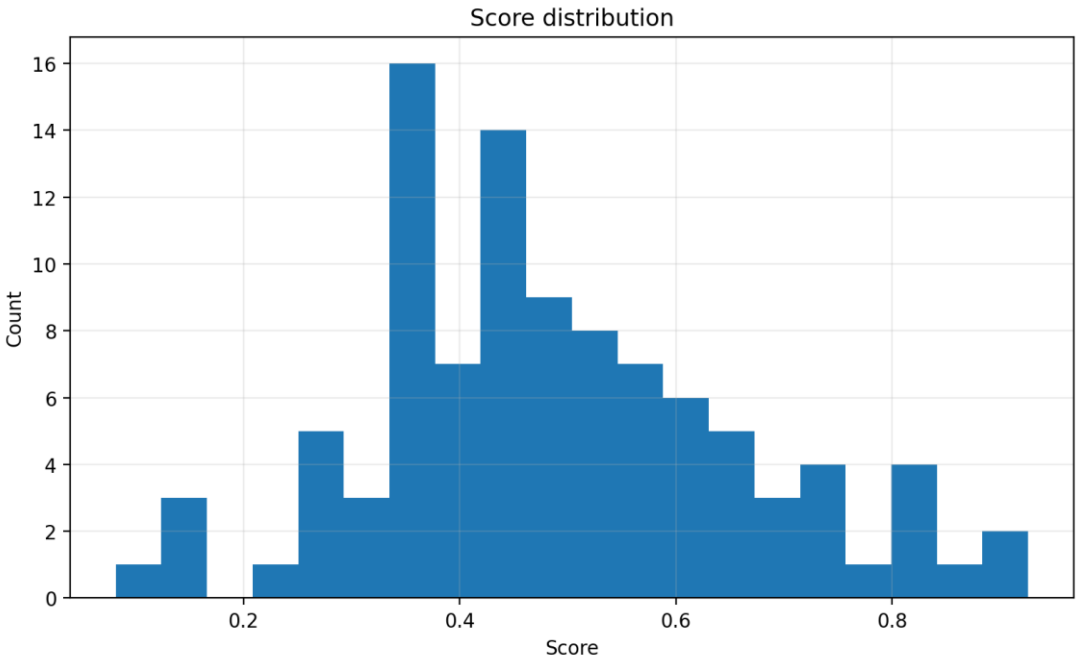
Параметър	Стойност	Роля
Макс. СЦЛП конфигурации	50	При основния праг 0.70

Петте индикатора включват три разходни - Price, Losses и BatteryWear - и два полезностни - CO2Saved и Flexibility. Нормализаторът обръща разходните показатели, така че в аналитичното пространство стойност 1 винаги означава по-добро представяне. Суровият генератор създава цената като случайна величина с допълнително топлинно натоварване; загубите и износването са свързани с цената; гъвкавостта намалява с нарастването на загубите; CO2Saved се генерира независимо в зададен диапазон. Това създава едновременно корелационна и независима структура.

5.2. Референтни сценарии и базова проверка

При базовите тегла [0.25, 0.15, 0.20, 0.20, 0.20] разпределението е 34 решения в low, 53 в medium и 13 в high. Тези три групи са резултат от праговете 0.40 и 0.70, а не от клъстерен алгоритъм. Най-високата наблюдавана оценка е 0.925689 за решение 58.

СЦЛП моделът намира минимална кардиналност 4 и пет различни минимални носителя за прага 0.70, което може да бъде проследено от ограниченията и теглата. Теоретичната максимално достижима оценка при структурните ограничения е 1.0.



Фигура 1: Разпределение на оценките в базовата система и граници на оценъчните класове.

При базовата система крайните оценки на 100-те наблюдавани конфигурации варират от приблизително 0.082 до 0.926. Средната стойност е 0.487, медианата е 0.462, а стандартното отклонение е приблизително 0.174. Първият и третият квартил са съответно 0.372 и 0.590, което означава, че половината от наблюдаваните конфигурации имат оценки приблизително между 0.37 и 0.59. Разпределението е слабо асиметрично надясно, т.е. наблюдават се ограничен брой конфигурации с относително високи оценки, които изтеглят средната стойност над медианата.

Поставените прагове 0.40 и 0.70 разделят наблюденията на 34 конфигурации в ниския, 53 в средния и 13 във високия оценъчен клас. От графиката се вижда, че основната маса от решенията е концентрирана около средния оценъчен диапазон, докато високият клас представлява сравнително малка част от извадката.

Изводът, който може да се направи е, че базовата система не поражда равномерно разпределение на крайните оценки. Преобладават конфигурации със средно представяне, а достигането на високия праг 0.70 е сравнително селективно условие. Това оправдава последващия анализ на това какво отличава високите конфигурации и какво не достига на останалите.

5.3. Експерименти с различен брой активни индикатори

Основният сценарий запазва пет индикатора, но прагова серия показва как се изменя минималният брой активни индикатори, необходим за достигане на различни целеви нива. Така се изследва структурната кардиналност на достатъчните конфигурации, без да се променя размерността на самата индикаторна система. До праг 0.45 са достатъчни два активни индикатора; при 0.50-0.65 минимумът е три; при 0.70-0.85 е четири; а при 0.90 са необходими всичките пет.

Този резултат илюстрира основната структурна идея: необходимият брой активни индикатори не е фиксирана характеристика сам по себе си, а зависи от целевото ниво и тегловната структура. По-високият праг намалява броя на алтернативните минимални носители и увеличава необходимата кардиналност. Експериментът не променя общия брой n=5; той сравнява минималния брой участващи индикатори в рамките на една и съща система.

5.4. Експерименти с различни теглови структури

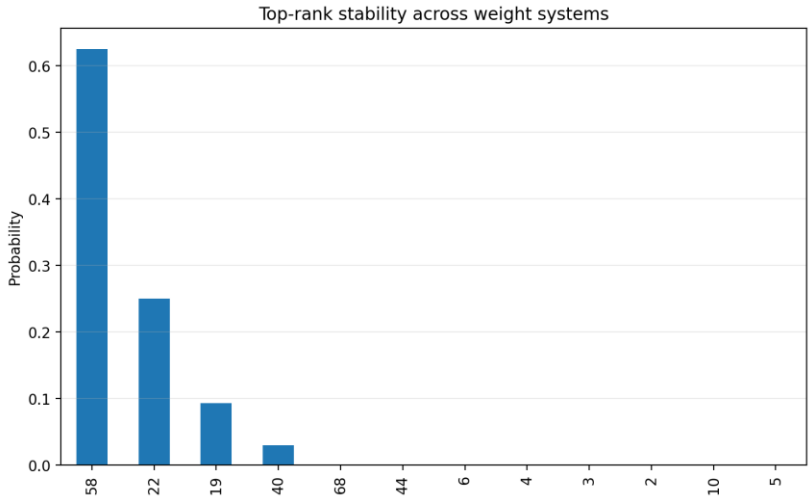
Таблица 3: Теглови структури на експериментите

Тегловен режим	Различни победители	Най-чест победител	Честота на победителя	Сума за топ 5
Равномерно Дирихле, α=1	6	58	0.625	0.999
Балансирано, α=5	4	58	0.756	1.000
Концентрирано, α=0.35	5	58	0.558	1.000

Глобалният анализ сравнява три тегловни режима при един и същ X: равномерно Дирихле α=1, балансирано α=5 и концентрирано α=0.35. Решение 58 остава най-чест победител и в трите режима, но честотата му се изменя от 0.558 до 0.756.

По-важният за настоящата работа резултат е структурният брой индикатори. При α=1 медианният теоретичен минимум е 2, медианният наблюдаван минимум - 3, а типичният наблюдаван брой - 3. При балансирания режим съответните стойности са 3, 4 и 4; при концентрирания режим - 2, 2 и 2. Медианният ефективен брой индикатори е съответно 3.166, 4.430 и 2.189.

Така балансираните тегла разпределят влиянието върху по-голям брой индикатори, докато концентрираните системи могат да достигат същия праг чрез по-малко доминиращи показатели. Това е именно структурната характеристика, която глобалният анализ цели да разкрие.



Фигура 2: Вероятност за първо място при глобално вариране на теглата.

Фигурата 2 показва емпиричната честота, с която отделните решения заемат първо място при 1000 тегловни вектора, генерирани от равномерно разпределение на Дирихле върху тегловния симплекс. Само шест от 100-те решения достигат първо място поне веднъж. Решение 58 доминира ясно, като е първо при 62.5% от тегловните системи, следвано от решение 22 с 25.0%, решение 19 с 9.3% и решение 40 с 3.0%; останалите победители се появяват само единично. Това съответства на резултатите от глобалния анализ.

Разпределението е силно концентрирано: първите две решения заедно заемат първо място в 87.5% от изследваните тегловни системи, а първите четири практически изчерпват наблюдаваните случаи. Следователно промяната на теглата променя победителя, но не води до произволно разпределение на първото място между всички алтернативи.

Изводът, който се налага е, че решение 58 проявява висока устойчивост спрямо варирането на теглата, но не е абсолютно устойчиво. Наличието на няколко алтернативни победители показва, че изборът на тегловна структура има значение и че глобалният анализ добавя информация, която не може да се получи само от базовото класиране.

5.5. Експерименти с различни прагове и ограничения

Таблица 4: Прагови ограничения

Целева оценка	Минимален брой активни индикатори	Брой минимални носители
0.30	2	10
0.35	2	10
0.40	2	7
0.45	2	3
0.50	3	10
0.55	3	10
0.60	3	7
0.65	3	3
0.70	4	5
0.75	4	5
0.80	4	4
0.85	4	1
0.90	5	1

Прагът е систематично изменян от 0.30 до 0.90. Получената стъпаловидна промяна на минималния брой активни индикатори показва границите, при които системата преминава от двуиндикаторни към три-, четири- и петиндикаторни минимални конфигурации.

При основния праг 0.70 се намират пет минимални носителя с по четири активни индикатора. Следователно при базовите тегла нито един тройно активен носител не е достатъчен за достигане на високия праг в непрекъснатия оптимизационен модел.

5.6. Резултати от локалния анализ

Локалният анализ дава три различни типа информация. Първо, праговата класификация разделя 100-те наблюдения на 34 low, 53 medium и 13 high. Второ, СЦЛП оптимизацията при τ=0.70 намира минимална кардиналност 4 и пет алтернативни минимални носителя. Трето, анализът на недостига се прилага към 87-те наблюдения под високия праг.

Таблица 5: Резултати от локален анализ

№	Активен носител	Нормализирани стойности P;L;BW;CO2;F	Оценка
1	Price, BatteryWear, CO2Saved, Flexibility	1.000; 0.000; 1.000; 1.000; 0.250	0.700
2	Price, Losses, BatteryWear, Flexibility	1.000; 0.333; 1.000; -0.000; 1.000	0.700
3	Price, Losses, BatteryWear, CO2Saved	1.000; 0.333; 1.000; 1.000; -0.000	0.700
4	Price, Losses, CO2Saved, Flexibility	1.000; 0.333; 0.000; 1.000; 1.000	0.700
5	Losses, BatteryWear, CO2Saved, Flexibility	0.000; 0.667; 1.000; 1.000; 1.000	0.700

Илюстративно решение 6 има оценка 0.688669. Минималният план за достигане на 0.70 увеличава нормализирания Price с 0.045323 в benefit-ориентираното пространство и достига точно целевата стойност. Така процедурата дава интерпретируем отговор „какво не достига“, вместо само да маркира решението като неуспешно.

За близо максималните алтернативи при абсолютен толеранс 0.03 се откриват две наблюдавани решения: решение 58 с 0.925689 и решение 22 с 0.903203. Разликата на второто до най-добрата наблюдавана оценка е 0.022486. Това показва, че системата има повече от една практически близка до максимума конфигурация.

5.7. Резултати от профилирането на оценъчните класове, съвместната поява и взаимозаменяемостта

Профилите са изчислени директно по трите предварително определени класа. Средните нормализирани стойности на low са [0.300, 0.359, 0.447, 0.461, 0.013], на medium

- [0.581, 0.618, 0.618, 0.558, 0.246], а на high - [0.862, 0.900, 0.803, 0.644, 0.792]. Представителните реални наблюдения са съответно решения 5, 17 и 96.

Таблица 6: Профилиране на оценъчните класове

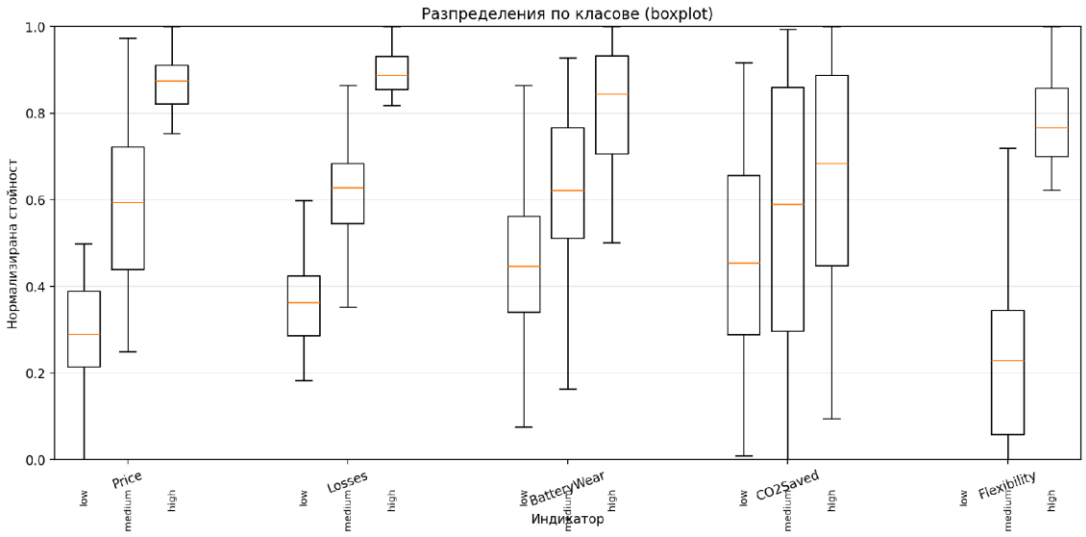
Оценъчен клас	Размер	Price	Losses	BatteryWear	CO2Saved	Flexibility	Представител
low	34	0.300	0.359	0.447	0.461	0.013	5
medium	53	0.581	0.618	0.618	0.558	0.246	17
high	13	0.862	0.900	0.803	0.644	0.792	96

Разликите между профилите са съдържателно свързани с оценъчния механизъм: високият клас не е „открит“ като естествен клъстер, а е определен от прага 0.70. Профилирането показва как изглеждат типичните конфигурации в този предварително известен клас.

Анализът на достатъчните комбинации при праг на активност 0.60 намира комбинацията {CO2Saved, Flexibility} с support 0.09 и confidence 1.00: тя се среща в 9 наблюдения и всичките 9 са успешни спрямо $\tau = 0.70$. Резултатът е структурна асоциация в конкретния набор, а не причинно твърдение.

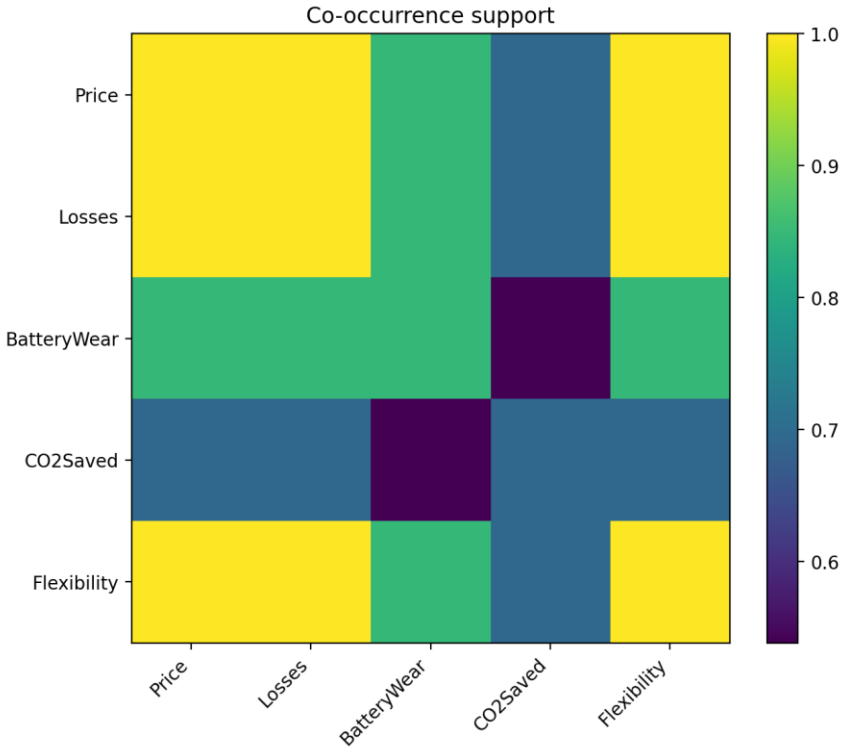
Матрицата на взаимозаменяемостта показва доколко максимализирането на един индикатор може да компенсира изключването на друг при запазен праг. Анализът е насочен и трябва да се интерпретира заедно с теглата и ограниченията.

Неконтролирана клъстеризация не е използвана в основния експеримент. Тя остава налична в кода като опционален режим само за бъдещи въпроси за вътрешни подтипове.



Фигура 3: Профили на конфигурациите по предварително зададен оценъчен клас.

Описателен анализ на структурата на вече формираните класове е показан чрез Фигура 3. Тя ясно показва изместване на разпределенията на Price, Losses, BatteryWear и особено Flexibility при преминаване от low към high. Най-силно разделяне на класовете се наблюдава при Flexibility, докато при CO2Saved разпределенията се припокриват значително. Това показва, че отделните индикатори имат различна способност да характеризират оценъчните класове и че високата крайна оценка се формира чрез комбинираното им действие, а не чрез един универсално доминиращ показател.



Фигура 4: Матрица на съвместната поява на силно проявени индикатори.

На Фигура 4 е представена матрица на съвместната поява на силно проявени индикатори. Това не е корелационна матрица, и не я разглеждаме и тълкуваме като такава. Матрицата е изчислена за конфигурациите, достигащи целевия праг 0.70, като за „силно проявен“ се приема индикатор с нормализирана стойност поне 0.60. Понеже високият клас съдържа 13 наблюдения, стойностите в матрицата могат да се интерпретират непосредствено като относителни честоти в тази малка група. Например стойност 0.846 съответства на 11 от 13 конфигурации, 0.692 - на 9 от 13, а 0.538 - на 7 от 13.

Price, Losses и Flexibility са силно проявени във всички високорезултатни конфигурации в разглежданата извадка, поради което техните диагонални честоти са 1.00. BatteryWear е силно проявен в приблизително 84.6% от тях, а CO2Saved - в приблизително 69.2%. Съвместната силна проява на Price и Losses, както и на тези индикатори с Flexibility, достига 1.00, докато най-ниската наблюдавана двойкова съвместна честота е между BatteryWear и CO2Saved - приблизително 0.538.

Това се съгласува и с установената достатъчна комбинация {CO2Saved, Flexibility}, която в целия набор има support 0.09 и confidence 1.00.

Изводът тук е, че високият клас не се характеризира с една-единствена задължителна двойка показатели, а с няколко често съвместно проявени структури. В същото време CO2Saved участва по-неустойчиво от останалите индикатори, което подсказва по-голяма възможност той да бъде компенсиран от други показатели.

Таблица 7: Таблица на състоянията

Изключен → активиран	**Price**	**Losses**	**BatteryWear**	**CO2Saved**	**Flexibility**
Price	1.000	0.000	0.077	0.231	0.000
Losses	0.462	1.000	0.538	0.769	0.462
BatteryWear	0.538	0.308	1.000	0.615	0.538
CO2Saved	0.333	0.333	0.583	1.000	0.500
Flexibility	0.462	0.385	0.538	0.538	1.000

5.8. Резултати от глобалния анализ

При основната тегловна извадка от 1000 вектора с Dirichlet α=1 теоретичният минимален брой индикатори има медиана 2, наблюдаваният минимален брой - медиана 3, а типичният наблюдаван брой сред успешните конфигурации - медиана 3. Третият квартил на типичния брой е 4, което показва, че значима част от тегловните системи изискват по-широко участие.

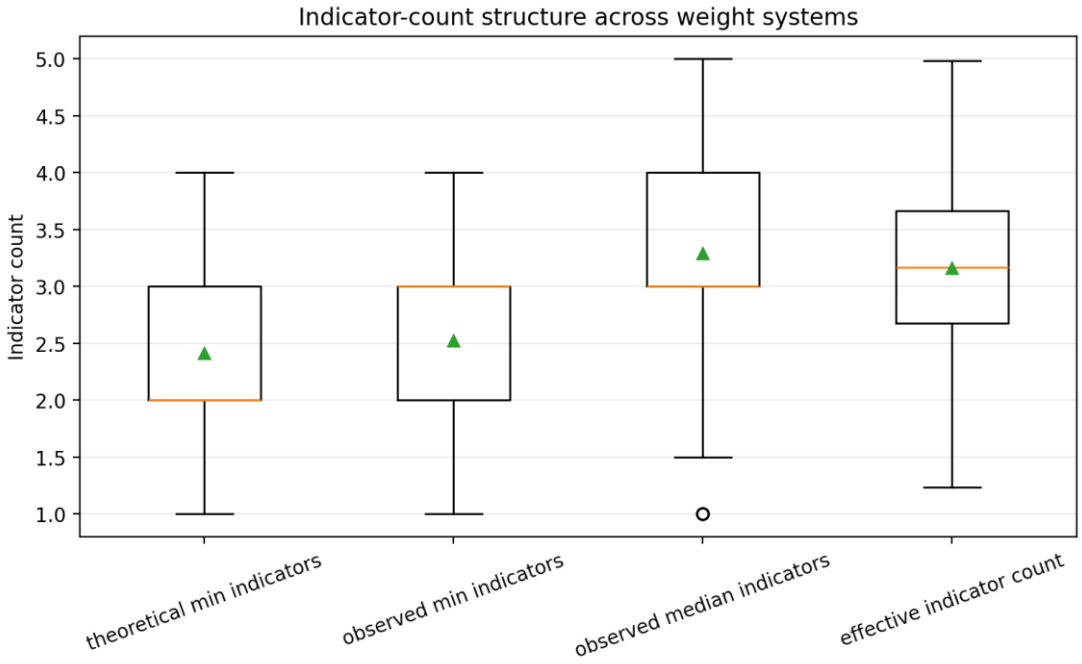
Таблица 8: Резултати от глобалния анализ

Индикатор	**Дял тегловни системи със силна глобална проява**
Price	0.907
Losses	1.000
BatteryWear	0.999
CO2Saved	0.375
Flexibility	0.875

Ефективният брой индикатори има медиана 3.166, а максималното единично тегло - медиана 0.439. В крайни случаи N_{eff} пада до 1.235 и максималното тегло достига 0.895, което характеризира силно концентрирани тегловни структури.

Сравнението на режимите потвърждава очакваната зависимост: α=5 води до по-балансирани системи и медианен ефективен брой 4.430, докато α=0.35 води до по-концентрирани системи и медиана 2.189. Тези стойности дават количествена основа за обсъждане на „реалистичен“ брой индикатори, без да се въвежда произволно един нормативен брой.

Честотата на силно проявените индикатори при праг 0.80 е Price 0.907, Losses 1.000, BatteryWear 0.999, CO2Saved 0.375 и Flexibility 0.875. Следователно CO2Saved е чувствително по-зависим от тегловната структура, докато Losses и BatteryWear се проявяват силно почти навсякъде.



Фигура 5: Разпределение на структурните показатели за необходимия брой индикатори при глобалния анализ.

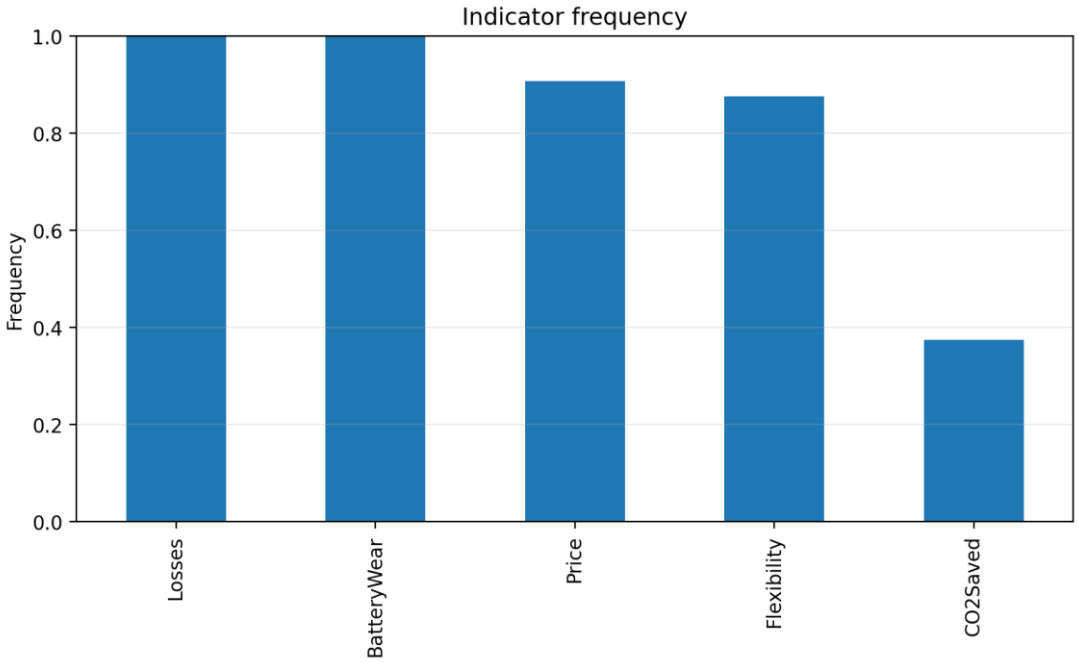
На Фигурата 5 се сравняват четири различни характеристики на структурата при 1000 тегловни системи. Теоретичният минимален брой индикатори има медиана 2 и интерквартилен диапазон от 2 до 3. Минималният брой водещи наблюдавани приноси, достатъчни за достигане на прага, има медиана 3 и интерквартилен диапазон 2-3. Типичният наблюдаван брой има медиана 3, но по-висок първи и трети квартил - съответно 3 и 4.

Ефективният брой индикатори има медиана 3.166 и интерквартилен диапазон приблизително 2.676-3.664.

Разликата между теоретичния и наблюдавания показател е особено важна. Макар тегловната структура в идеализирания случай често да позволява прагът да бъде достигнат чрез два силни индикатора, реалните наблюдавани конфигурации по-често изискват три или повече съществени приноса. Типичният брой е още по-висок, което показва, че минимално възможната структура не е непременно характерна за повечето успешни решения.

Ефективният брой индикатори дава допълнителна информация: той не измерва директно достигането на прага, а концентрацията на теглата. Стойности около 3 означават, че влиянието обичайно е разпределено между няколко показателя, а не е напълно концентрирано в един.

Може да се направи заключението, че глобалната структура не може да бъде описана с един-единствен „необходим брой индикатори“. Теоретичната долна граница, наблюдаваната достатъчност и тегловният баланс измерват различни свойства. Съвместното им разглеждане показва, че практически успешната система обикновено използва по-широка структура от математически минимално възможната.



Фигура 6: Честота на силно проявените индикатори при вариращи тегла.

На Фигура 6 е показано колко често всеки индикатор има нормализирана стойност поне 0.80 в решенията, които заемат първо място при 1000 вариращи тегловни системи. Losses достига тази граница във всички случаи - честота 1.000, а BatteryWear почти във всички - 0.999. Следват Price с 0.907 и Flexibility с 0.875. Значително по-ниска е честотата на CO2Saved - 0.375. Тези стойности са представени и в табличната част на глобалния анализ.

Тази разлика показва, че характеристиките на глобално водещите решения не са еднакво устойчиви спрямо тегловния избор. Losses и BatteryWear остават високо представени почти независимо от конкретната тегловна система, а Price и Flexibility също проявяват висока, макар не абсолютна устойчивост. За разлика от тях CO2Saved е силно проявен само при около 37.5% от победителите.

Може да се обобщи, че CO2Saved е индикаторът, чиято силна проява е най-зависима от конкретната тегловна структура, докато Losses и BatteryWear характеризират почти всички глобално водещи конфигурации. Това не означава, че последните са статистически или причинно „по-важни“ по принцип, а че в конкретния синтетичен сценарий са най-устойчивите характеристики на решенията, които стават първи при вариране на теглата.

Таблица 9: Q1-Q4 по показатели

Показател	Минимум	Q1	Медиана	Q3	Максимум
Теоретичен минимум индикатори	1.000	2.000	2.000	3.000	4.000
Най-добър наблюдаван минимум	1.000	2.000	3.000	3.000	4.000
Типичен наблюдаван брой	1.000	3.000	3.000	4.000	5.000
Ефективен брой индикатори	1.235	2.676	3.166	3.664	4.984
Максимално единично тегло	0.213	0.377	0.439	0.526	0.895

5.9. Сравнение на локални и глобални резултати

Локалният и глобалният анализ отговарят на различни въпроси и затова резултатите им не трябва да се смесват. Локално, при фиксираните базови тегла, високият праг 0.70 изисква минимум четири активни индикатора в непрекъснатия СЦЛП модел, а само 13 от 100-те наблюдавани конфигурации са в high.

Глобално, при вариране на теглата, теоретичният минимум често е 2, но наблюдаваният минимум и типичният брой са по-високи. Това различие показва защо е

полезно да се разграничат идеализирана структурна достатъчност и действително реализирана достатъчност в наличния набор от данни.

По този начин локалният анализ показва как работи конкретната система и как да се достигнат нейните условия, а глобалният показва доколко самата система от индикатори е концентрирана, балансирана и структурно зависима от тегловния избор.

5.10. Изчислителна ефективност и възпроизводимост

Експериментът се изпълнява възпроизводимо със seed=101 и записва табличните резултати и фигурите в отделна изходна директория. 14-те автоматични теста преминават успешно след преработката.

Основният изчислителен товар идва от многократното решаване на СЦЛП задачи при изброяването на носители и от оценяването на много тегловни системи. Глобалното преоценяване на фиксиран X е векторизирано, а изследователската клъстеризация е изключена по подразбиране, което премахва ненужна квадратична матрица на разстоянията от основния поток.

Глава 6. Обсъждане на резултатите

Резултатите потвърждават основната предпоставка на работата: крайният композитен резултат не описва изчерпателно поведението на една линейна многокритериална система. При една и съща базова система съществуват множество математически минимални носители, наблюдаваната извадка съдържа различна от тях емпирична структура, а варирането на теглата променя състава на високия клас и относителната важност на индикаторите. Следователно пространството от конфигурации предоставя информация, която не може да бъде възстановена само от единична крайна оценка.

6.1. Отговори на изследователските въпроси

RQ1 получава положителен отговор чрез комбинация от прагово класифициране, СЦЛП оптимизация, анализ на недостига и близо максимални алтернативи. При $\tau=0.70$ базовата система има пет минимални носителя с кардиналност 4; 87 наблюдения са под high и могат да бъдат анализирани за минимална необходима промяна; две наблюдавани решения са в рамките на 0.03 от най-доброто.

RQ2 се адресира чрез фиксиране на X и вариране само на w. Теоретичният минимум, наблюдаваният минимум, типичният наблюдаван брой и ефективният брой индикатори дават различни, но допълващи се аспекти на структурната достатъчност и баланс.

RQ3 показва, че праговите класове могат да бъдат профилирани без неконтролирана клъстеризация. Допълнително се открива достатъчната комбинация {CO2Saved, Flexibility}, изчисляват се съвместна поява, взаимозаменяемост и стабилна глобална проява.

RQ4 е реализиран чрез единен Python пакет с възпроизводими настройки, програмно генерирани таблици и фигури и 14 преминаващи автоматични теста.

6.2. Съпоставка с разгледаните подходи

Резултатите са съвместими с класическата логика на адитивните модели: крайният резултат е компенсаторен и различни профили могат да достигнат един и същ праг [6], [14], [17]. Използването на СЦЛП добавя експлицитна структурна цел - минимален брой активни индикатори - която не се вижда от самата претеглена сума [27], [28].

Глобалното вариране на теглата следва традицията на анализ на чувствителността в тегловното пространство [2], [3], [7], [22], но тук фокусът е изместен от промяната на ранга към минималния и типичния брой достатъчни индикатори и към баланса на тегловното влияние.

Разграничението между прагови класове и клъстери е методологично важно. Клъстерните методи от литературата [40]-[42] остават полезни за изследователска подструктура, но не са необходими за възстановяване на класове, които системата вече дефинира чрез прагове.

6.3. Интерпретация на типовете конфигурации и класовете системи

Трите оценъчни класа показват ясно нарастващи профили от low към high. Това позволява да се интерпретира системата като преход от недостатъчни конфигурации, през междинни, към конфигурации, които покриват високото условие. Профилите не са „естествени клъстери“, а описания на нормативно зададени регистри.

Глобалните тегловни системи се интерпретират чрез степента на концентрация и необходимия брой индикатори. Балансираните тегла изискват по-широко участие, докато концентрираните позволяват по-малък брой доминиращи индикатори. Следователно структурният избор не се свежда до „колкото по-малко, толкова по-добре“: малката кардиналност може да е признак и за прекомерна концентрация.

Практически разумният дизайн се търси между две крайности - излишно много показатели и система, доминирана от един-два показателя. Типичният наблюдаван брой и N_{eff} предоставят количествени ориентири за този баланс, но окончателният избор остава предметно зависим.

6.4. Научен и приложен принос

Методологичният принос е единна интерпретация на локалния и глобалния анализ. Локалният модул отговаря на въпросите за покриване на праг, недостиг и близо максимални алтернативи. Глобалният модул превръща варирането на теглата в структурен анализ на необходимия и ефективния брой индикатори.

Софтуерният принос е инструмент, който реализира тези процедури в обща възпроизводима архитектура, позволява индивидуално разпределение на всеки синтетичен индикатор и делегира СЦЛП решаването на HiGHS чрез scipy.optimize.milp.

Интеграционният принос е съчетаването на минимални конфигурации, прагови профили, Парето анализ, съвместна поява, взаимозаменяемост и тегловна устойчивост без смесване на ролята на предварително зададените класове с ролята на неконтролираното групиране.

6.5. Ограничения и заплахи за валидността

Основните ограничения са линейността и компенсаторността на модела, синтетичният характер на данните, зависимостта от избраните прагове и тегловни извадки и възможната комбинаторна експлозия при по-голям брой индикатори. Резултатите от сценария не трябва да се генерализират към реална предметна област без допълнителна емпирична проверка.

Планът за недостиг допуска само положителни изменения в benefit-ориентираното нормализирано пространство и минимизира общата им сума; това е конкретна дефиниция на „най-малка промяна“, а не универсална мярка за реална цена. Типичният наблюдаван брой индикатори също зависи от X и τ.

Ефективният брой индикатори измерва баланс на теглата, но не измерва съдържателна пълнота на индикаторната система. По тази причина глобалният анализ представя няколко показателя едновременно и не извежда автоматична универсална препоръка за точен брой индикатори.

Неконтролираната клъстеризация е оставена като опционална функционалност и не е използвана в основния експеримент. Това намалява риска алгоритмично открити групи да бъдат погрешно интерпретирани като нормативните класове low/medium/high.

Заключение

Обобщение на постигнатите резултати

Разработена е единна рамка за анализ на линейни многокритериални системи, която разглежда едновременно поведението на конкретна система и структурата на системата от индикатори при вариращи тегла. Моделът използва нормализирани индикатори, претеглена сума, прагови класове и линейни структурни ограничения.

Локалният анализ намира допустими и минимални конфигурации, изчислява какво не достига до зададен праг и извлича близо максимални алтернативи. Глобалният анализ поддържа постоянен набор от данни и варира само теглата, като измерва теоретичен минимум, наблюдаван минимум, типичен и ефективен брой индикатори.

Софтуерният инструмент е преработен съобразно тази логика. Основните класове са прагово дефинирани, клъстеризацията е опционална, синтетичният генератор поддържа индивидуални разпределения по индикатор, а СЦЛП задачите се решават чрез SciPy/HiGHS. Експерименталният сценарий е изпълнен повторно и всички 14 теста преминават.

Основни приноси

Основните приноси са:

1. Формализирано разграничение между локален анализ на конкретна система при фиксирани тегла и глобален структурен анализ при вариращи тегла върху постоянен набор от данни.

2. Локална оптимизационна процедура за минимални конфигурации, минимален недостиг до праг и близо максимални наблюдавани алтернативи.

3. Глобални показатели за теоретичен минимум, наблюдаван минимум, типичен наблюдаван и ефективен брой индикатори, които разграничават компактност от тегловен баланс.

4. Ясно отделяне на предварително зададените оценъчни класове от неконтролираната клъстеризация и директно профилиране на класовете.

5. Разширен генератор с индивидуални вероятностни разпределения по индикатор и възпроизводима Python реализация с програмно генерирани резултати и визуализации.

Насоки за бъдещо развитие

Бъдещото развитие може да включи реални приложни данни, нелинейни и йерархични оценъчни функции, цени на промените по индикатори вместо еднаква L1 мярка, динамични тегла и по-мащабни алгоритми за изброяване на минимални носители.

За глобалния анализ може да се разработи предметно обусловен критерий за препоръчителен брой индикатори, който съвместява N_{eff} , типичния наблюдаван брой, информационно покритие и цена на измерването. Опционалната клъстеризация може да се използва за търсене на подтипове само след формулиране на конкретна допълнителна хипотеза.

Аналитичната част на разработената рамка може да бъде разширена с допълнителни статистически методи за оценяване на неопределеността и устойчивостта на получените резултати. Такива разширения могат да включват доверителни интервали и стандартни грешки за Monte Carlo оценки, bootstrap процедури за профилите и честотите на достатъчните комбинации, повторни експерименти при различни начални стойности на генератора на псевдослучайни числа, анализ на чувствителността спрямо параметрите на използваните разпределения, както и статистически сравнения между различни тегловни режими. При наличие на реални данни рамката може да бъде допълнена и с регресионни, байесови и други статистически модели за оценяване на зависимостите между индикаторите и неопределеността на изводите. Тези методи не променят основната локално-глобална постановка, а разширяват аналитичния слой върху вече получените пространства от решения и конфигурации.

Практическо разширение е уеб интерфейс за задаване на индивидуални разпределения, прагове и ограничения и за интерактивно сравнение на локални и глобални резултати.

Приложения

Приложение 1. Описание на входните данни

Индикатор	Тип	Роля в единствения сценарий	Локален праг
Price	разход	Паричен/ценови индикатор; след нормализация по-ниската сурова стойност е по-добра.	0.10
Losses	разход	Загуби; в синтетичния генератор са свързани с Price.	0.10
BatteryWear	разход	Износване на батерията; синтетично свързано с Price.	0.10
CO2Saved	полза	Спестени емисии; по-висока сурова стойност е по-добра.	0.10
Flexibility	полза	Гъвкавост; в генератора намалява с увеличаване на Losses.	0.10

Суровият CSV файл marin_heatwave_raw.csv съдържа 100 реда. Нормализираният файл marin_heatwave_normalized.csv съдържа същите решения в общата скала [0,1]. Трите разходни критерия се обръщат при нормализацията. Всички експериментални анализи използват нормализираното представяне.

Приложение 2. Параметри на експерименталния сценарий

Параметър	**Стойност**
seed	101
target_score	0.70
n_weight_samples	1000
weight_mode	dirichlet, α=1 за основния анализ
near_optimal_tolerance	0.03
exploratory_clustering	False
exploratory_global_system_clustering	False
cooccurrence_active_threshold	0.60
stable_indicator_active_threshold	0.80
sufficient_max_size	3
sufficient_min_support	0.05
sufficient_min_confidence	0.90
max_milp_solutions	50

Таблицата съдържа параметрите, използвани при повторното изпълнение на единствения експериментален сценарий. Неконтролираната клъстеризация е изключена в основния поток, а tol=0.03 определя близо максималните наблюдавани решения.

Приложение 3. Инсталиране и работа със софтуерния инструмент

Основният пакет mcda_space съдържа модули models, normalization, generators, local_analysis, global_analysis, analytics, sensitivity, pipeline, visualization, reporting и io. Пълните инструкции за инсталация и изпълнение са в README.md на приложения архив, а така също и в настоящето приложение.

Основен възпроизводим сценарий:

PYTHONPATH=python examples/marin_microgrid_test.py

Тестове: PYTHONPATH=pytest -q

Настоящото приложение описва практическите стъпки за инсталиране, проверка и стартиране на разработения Python инструмент за анализ на пространствата от решения и конфигурации в линейни многокритериални системи за оценка. Описани са както изпълнението на включените примерни сценарии, така и анализът на потребителски CSV/Excel данни чрез конфигурационен JSON файл.

1. Системни изисквания

Проектът е реализиран на Python и според конфигурацията в pyproject.toml изисква Python 3.11 или по-нова версия. Инсталацията, описана по-долу, е проверена и с Python 3.14.3 под Windows.

Основните използвани библиотеки са:

- NumPy - числени изчисления и работа с многомерни масиви;
- pandas - таблични структури и обработка на данни;
- SciPy - оптимизационни процедури, включително MILP;
- Matplotlib - генериране на графики;
- openpyxl - четене на Excel файлове;
- pytest - автоматизирано тестване на основните програмни компоненти.

2. Структура на програмния пакет

След разархивиране основната директория на проекта съдържа програмния пакет mcda_space, директории с примери и тестове, както и файловете за инсталация и командно стартиране. За изпълнение на командите трябва да се работи от основната директория на

проекта - тази, в която едновременно се намират mcda_space, examples, tests, pyproject.toml, requirements.txt и run_analysis.py.

```
mcda_solution_space_tool/
    ├── mcda_space/
    ├── examples/
    ├── tests/
    ├── run_analysis.py
    ├── requirements.txt
    ├── pyproject.toml
    └── README.md
```

3. Инсталиране под Windows

3.1. Отваряне на основната директория

Архивът със сорс кода се разархивира в избрана директория. След това се отваря Command Prompt или PowerShell и текущата директория се сменя към основната директория на проекта. Когато пътят съдържа интервали или символи на кирилица, той трябва да бъде поставен в кавички.

```
cd /d "C:\път\до\mcda_solution_space_tool"
```

3.2. Проверка на използваната версия на Python

За да се избегне инсталиране на зависимостите в различна Python среда, препоръчително е първо да се провери версията на интерпретатора.

```
py -3.14 --version
```

Ако системата използва друга версия на Python 3.11 или по-нова, номерът 3.14 се заменя с наличната версия. При системи без Python Launcher може да се използва командата python вместо py -3.14.

3.3. Инсталиране на зависимостите

От основната директория на проекта се инсталират библиотеките, описани във файла requirements.txt:

```
py -3.14 -m pip install -r requirements.txt
```

3.4. Инсталиране на програмния пакет

След инсталиране на зависимостите проектът се регистрира в текущата Python среда в editable режим. Тази стъпка е съществена, защото позволява модулът mcda_space да бъде импортиран от примерните скриптове, от IDLE и от потребителски програми.

```
py -3.14 -m pip install -e .
```

3.5. Проверка на инсталацията

Коректната регистрация на пакета може да се провери с:

```
py -3.14 -c "import mcda_space; print(mcda_space.__file__)"
```

При успешна инсталация командата извежда път към файла mcda_space__init__.py. Това потвърждава, че пакетът е достъпен за използвания Python интерпретатор.

3.6. Препоръчителна изолирана среда

За възпроизводима работа е препоръчително проектът да се изпълнява във виртуална среда. Тя изолира използваните версии на библиотеките от останалите Python проекти.

```
py -3.14 -m venv .venv
.venv\Scripts\activate
python -m pip install -r requirements.txt
python -m pip install -e .
```

4. Стартиране на включените примери

След успешна инсталация примерните сценарии могат да се стартират от основната директория на проекта. Всеки пример използва общия пакет mcda_space, а резултатите се записват в съответна изходна директория.

4.1. Предметно независим пример

```
py -3.14 examples\marin_proposal_demo.py
```

Този пример демонстрира основния работен поток на инструмента чрез неутрална многокритериална система и генерира таблици и фигури в директорията examples\output_marin_demo.

4.2. Конкретен петиндикаторен тест

```
py -3.14 examples\marin_microgrid_test.py
```

Скриптът създава 100 синтетични алтернативи със seed 101, нормализира данните и изпълнява локален и глобален анализ, анализ на Парето, клъстеризация, анализ на достатъчни комбинации и взаимозаменяемост, както и сравнение на различни режими за генериране на тегла. Резултатите се записват в examples\output_marin_microgrid_test.

4.3. Произволно генериран пример

```
py -3.14 examples\random_demo.py
```

Примерът генерира синтетична система с осем индикатора и е подходящ за проверка на поведението на инструмента при различна размерност.

4.4. Шаблон за външна индикаторна система

```
py -3.14 examples\naoa_style_demo.py
```

Файлът служи като шаблон за адаптиране на инструмента към външна индикаторна система. Преди практическо използване се заменят имената и типовете на критериите, теглата, праговете и при необходимост линейните ограничения.

5. Стартиране чрез IDLE

Примерните Python файлове могат да бъдат отваряни и изпълнявани чрез IDLE. След инсталирането на пакета с pip install -e . се отваря желаният файл от директорията examples и се изпълнява с Run Module (F5).

При съмнение дали IDLE използва същия Python интерпретатор, в IDLE Shell може да се изпълни:

```
import sys
   print(sys.executable)
```

Полученият път може да се използва директно за инсталацията на зависимостите и пакета, например:

```
"C:\път\до\python.exe" -m pip install -r requirements.txt
   "C:\път\до\python.exe" -m pip install -e .
```

6. Анализ на потребителски CSV/Excel данни

Инструментът поддържа анализ на потребителски данни чрез командния файл run_analysis.py. Необходими са два входа: JSON конфигурация на модела и CSV или XLSX файл с данни. Примерна конфигурация е предоставена във файла examples\user_model.json, а примерен CSV файл - в examples\data\user_data.csv.

Примерна команда:

```
py -3.14 run_analysis.py ^
     --config examples\user_model.json ^
     --data examples\data\user_data.csv ^
     --output my_analysis ^
     --target 0.72 ^
     --weight-samples 1000 ^
     --weight-mode dirichlet
```

Параметърът --target задава целевия праг за локалния анализ и анализа на достатъчни комбинации; --weight-samples определя броя на генерираните теглови вектори; --weight-mode избира начина на генериране на теглата. Поддържаните режими са dirichlet, balanced, concentrated и equal.

При CSV/XLSX вход данните се нормализират автоматично. Ако са известни фиксирани референтни граници, те могат да бъдат зададени чрез raw_min и raw_max за съответните индикатори в JSON конфигурацията.

7. Основни изходни резултати

Интегрираният AnalysisPipeline генерира таблици и визуализации, които могат да бъдат използвани в експерименталната част на дипломната работа. Сред основните резултати са:

- нормализираните входни данни и таблица на решенията с оценка, клас и допустимост;
- Парето-недоминираните конфигурации;
- минималните наблюдавани и MILP минимални конфигурации;
- клъстерните профили, избраният брой клъстери и silhouette показатели;
- матрици за честота и съвместна поява, support и confidence;
- достатъчни комбинации и матрица на структурна взаимозаменяемост;
- глобални вероятности за класове и top-rank устойчивост;
- структурна устойчивост и клъстери на оценъчните системи;
- анализ на чувствителността по индикатори, тегла и прагове;
- графики за разпределение на оценките, профили, съвместна поява и устойчивост.

8. Автоматични тестове

Пакетът съдържа автоматични тестове за основните математически и програмни инварианти. След инсталация те се изпълняват от основната директория на проекта:

```
py -3.14 -m pytest
```

Тестовете проверяват валидността на теглата, определянето на класовете, работата на ограниченията, MILP анализа, тегловите извадки, глобалния анализ, Парето филтрирането, k-medoids клъстеризацията и silhouette оценката.

9. Отстраняване на често срещан проблем

При директно стартиране на файл от директорията examples преди инсталиране на проекта може да се появи следната грешка:

```
ModuleNotFoundError: No module named 'mcda_space'
```

Причината е, че Python не намира локалния пакет mcda_space в използваната среда. Коректното решение е да се премине в основната директория на проекта и да се изпълни:

```
py -3.14 -m pip install -e .
```

Не се препоръчва трайно добавяне на директории чрез sys.path.append(...), тъй като проектът разполага с pyproject.toml и е предназначен да бъде инсталиран като Python пакет. Ако грешката остане, трябва да се провери дали pip и средата, от която се стартира програмата, използват един и същ Python интерпретатор.

10. Препоръки за възпроизводима работа

За всяко експериментално изпълнение е препоръчително да се съхраняват всички параметри, необходими за повторното получаване на резултата. Минималният набор включва:

- JSON конфигурацията на модела;
- входния CSV/XLSX файл или параметрите на синтетичния генератор;
- използваната seed стойност;
- целевия праг target score;
- режима и размера на тегловата извадка;
- директорията с генерираните таблици и фигури;
- версията на Python и инсталираните зависимости.

Това позволява експериментите от дипломната работа да бъдат повторени и проверени независимо и подпомага проследимостта между зададен сценарий, получени резултати и тяхната интерпретация.

11. Кратка последователност за първо стартиране

За потребител, който вече разполага с Python 3.14, минималната последователност под Windows е следната:

```
cd /d "C:\път\до\mcda_solution_space_tool"
   py -3.14 -m pip install -r requirements.txt
```

```
py -3.14 -m pip install -e .
py -3.14 -c "import mcda_space; print(mcda_space.__file__)"
py -3.14 examples\marin_microgrid_test.py
```

Ако четвъртата команда изведе път към mcda_space__init__.py и последната команда стартира анализа без грешка при import, средата е конфигурирана коректно.

Приложение 4. Шаблон JSON

user_model.json

```json
{
  "name": "Example user-defined linear MCDA system",
  "indicators": [
    {"name": "criterion_A", "kind": "benefit", "active_threshold": 0.1},
    {"name": "criterion_B", "kind": "cost", "active_threshold": 0.1},
    {"name": "criterion_C", "kind": "benefit", "active_threshold": 0.1},
    {"name": "criterion_D", "kind": "benefit", "active_threshold": 0.1}
  ],
  "weights": [0.30, 0.20, 0.25, 0.25],
  "thresholds": {
    "boundaries": [0.45, 0.72],
    "labels": ["low", "medium", "high"]
  },
  "constraints": [
    {
      "name": "structural example",
      "coefficients": [1.0, 0.0, 1.0, 0.0],
      "sense": "<=",
      "rhs": 1.8
    }
  ],
  "max_active_indicators": 4
}
```

Фигура 7: Примерен конфигурационен шаблон user_model.json за потребителски анализ.

Шаблонът позволява потребителят да дефинира структурата на собствена линейна многокритериална система без промяна на програмния код. Чрез секцията indicators се задават имената, типът на критерия (benefit или cost) и прагът за активност на всеки индикатор. В weights се задават теглата, а чрез thresholds - границите и имената на оценъчните класове. Полето constraints позволява въвеждане на допълнителни линейни ограничения, а max_active_indicators ограничава максималния брой активни индикатори. Същият шаблон може да се използва с различни CSV или XLSX набори от данни, при условие че имената на колоните съответстват на зададените индикатори.

Възможни настройки чрез шаблона:

- name - име на оценъчната система;
- indicators - списък на индикаторите;
- за всеки индикатор: name, kind (benefit или cost) и active_threshold;
- weights - теглата на индикаторите;
- thresholds.boundaries - границите между оценъчните класове;
- thresholds.labels - имената на класовете;

- constraints - допълнителни линейни ограничения чрез коефициенти, знак и дясна страна;
- max_active_indicators - максимално допустим брой активни индикатори.

Параметрите на самото изпълнение - целева оценка, брой генерирани тегловни вектори и режим на тегловната извадка - се задават отделно чрез командния интерфейс, например чрез --target, --weight-samples и --weight-mode.

Приложение 5. Допълнителни резултатни таблици

Таблица П5.1. Парето-недоминирани решения в разглеждания експериментален сценарий.

ID	Оценка	Клас	Активни	Price	Losses	Wear	CO2	Flex
12	0.632929	medium	4	0.777	0.547	0.899	0.822	0.062
19	0.821940	high	5	0.753	0.851	0.837	1.000	0.692
22	0.903203	high	5	0.879	1.000	0.844	0.823	1.000
40	0.877338	high	5	0.911	0.901	0.889	0.888	0.796
44	0.839745	high	5	0.855	0.855	0.848	0.940	0.700
47	0.800730	high	5	0.938	0.939	0.570	0.684	0.873
58	0.925689	high	5	1.000	0.985	1.000	0.671	0.969
68	0.830894	high	5	0.875	0.887	0.706	0.922	0.767

Пълните таблици са налични в изходната директория на скрипта. В приложението е включено само компактно подмножество, което подпомага проверката на основния текст и не въвежда допълнителни примери.

Използвани фигури в текста (без приложенията)

Фигура 1: Разпределение на оценките в базовата система и граници на оценъчните класове. 39
Фигура 2: Вероятност за първо място при глобално вариране на теглата. 41
Фигура 3: Профили на конфигурациите по предварително зададен оценъчен клас. 44
Фигура 4: Матрица на съвместната поява на силно проявени индикатори. 45
Фигура 5: Разпределение на структурните показатели за необходимия брой индикатори при глобалния анализ. 47
Фигура 6: Честота на силно проявените индикатори при вариращи тегла. 48

Използвани таблици в текста (без приложенията)

Таблица 1: Архитектура на приложението 31
Таблица 2: Дизайн на експеримента 38
Таблица 3: Теглови структури на експериментите 41
Таблица 4: Прагови ограничения 42
Таблица 5: Резултати от локален анализ 43
Таблица 6: Профилиране на оценъчните класове 44
Таблица 7: Таблица на състоянията 46
Таблица 8: Резултати от глобалния анализ 46
Таблица 9: Q1-Q4 по показатели 49

Използвана литература

[1] J. Mazurek and D. Strzałka, “On the Monte Carlo weights in multiple criteria decision analysis,” PLOS ONE, vol. 17, no. 10, e0268950, 2022. doi: 10.1371/journal.pone.0268950.

[2] R. O’Shea, P. Deeney, E. Triantaphyllou, L. Diaz-Balteiro, and S. A. Tarim, “Weight stability intervals for multi-criteria decision analysis using the weighted sum model,” Expert Systems with Applications, vol. 296, art. 128460, 2026. doi: 10.1016/j.eswa.2025.128460.

[3] J. Więckowski and W. Sałabun, “Sensitivity analysis approaches in multi-criteria decision analysis: A systematic review,” Applied Soft Computing, vol. 148, art. 110915, 2023. doi: 10.1016/j.asoc.2023.110915.

[4] S. Greco, R. Słowiński, and J. Wallenius, “Fifty years of multiple criteria decision analysis: From classical methods to robust ordinal regression,” European Journal of Operational Research, vol. 323, no. 2, pp. 351-377, 2025. doi: 10.1016/j.ejor.2024.07.038.

[5] A. Williams and X. Cai, “Insights into Weighted Sum Sampling Approaches for Multi-Criteria Decision Making Problems,” WSEAS Transactions on Mathematics, vol. 24, pp. 327-346, 2025. doi: 10.37394/23206.2025.24.32.

[6] P. C. Fishburn, “Independence in Utility Theory with Whole Product Sets,” Operations Research, vol. 13, no. 1, pp. 28-45, 1965. doi: 10.1287/opre.13.1.28.

[7] J. Więckowski and W. Sałabun, “A new sensitivity analysis method for decision-making with multiple parameters modification,” Information Sciences, vol. 678, art. 120902, 2024. doi: 10.1016/j.ins.2024.120902.

[8] P. C. Fishburn, “Methods of Estimating Additive Utilities,” Management Science, vol. 13, no. 7, pp. 435-453, 1967. doi: 10.1287/mnsc.13.7.435.

[9] T. L. Saaty, The Analytic Hierarchy Process: Planning, Priority Setting, Resource Allocation. New York, NY, USA: McGraw-Hill, 1980.

[10] J. S. Dyer, P. C. Fishburn, R. E. Steuer, J. Wallenius, and S. Zionts, “Multiple Criteria Decision Making, Multiattribute Utility Theory: The Next Ten Years,” Management Science, vol. 38, no. 5, pp. 645-654, 1992. doi: 10.1287/mnsc.38.5.645.

[11] G. Demir, P. Chatterjee, and D. Pamučar, “Sensitivity analysis in multi-criteria decision making: A state-of-the-art research perspective using bibliometric analysis,” Expert Systems with Applications, vol. 237, art. 121660, 2024. doi: 10.1016/j.eswa.2023.121660.

[12] B. Ayan, S. Abacıoğlu, and M. P. Basílio, “A Comprehensive Review of the Novel Weighting Methods for Multi-Criteria Decision-Making,” Information, vol. 14, no. 5, art. 285, 2023. doi: 10.3390/info14050285.

[13] I. Hashem et al., “Recursive Objective Space Exploration (ROSE): A computationally efficient deterministic approach for bi-objective optimization,” PLOS ONE, vol. 20, no. 8, e0327994, 2025. doi: 10.1371/journal.pone.0327994.

[14] R. L. Keeney and H. Raiffa, Decisions with Multiple Objectives: Preferences and Value Tradeoffs. New York, NY, USA: Wiley, 1976.

[15] E. Triantaphyllou and A. Sánchez, “A Sensitivity Analysis Approach for Some Deterministic Multi-Criteria Decision-Making Methods,” Decision Sciences, vol. 28, no. 1, pp. 151-185, 1997. doi: 10.1111/j.1540-5915.1997.tb01306.x.

[16] OECD and Joint Research Centre, Handbook on Constructing Composite Indicators: Methodology and User Guide. Paris, France: OECD Publishing, 2008. doi: 10.1787/9789264043466-en.

[17] S. Greco, A. Ishizaka, M. Tasiou, and G. Torrisi, “On the Methodological Framework of Composite Indices: A Review of the Issues of Weighting, Aggregation, and Robustness,” Social Indicators Research, vol. 141, pp. 61-94, 2019. doi: 10.1007/s11205-017-1832-9.

[18] D. Brockhoff, M. Emmerich, B. Naujoks, and R. Purshouse, Eds., Many-Criteria Optimization and Decision Analysis: State-of-the-Art, Present Challenges, and Future Perspectives. Cham, Switzerland: Springer, 2023. ISBN: 978-3-031-25262-4.

[19] T. A. Weber, “Relatively Robust Multicriteria Decisions,” Management Science, vol. 72, no. 4, pp. 3175-3203, 2026 (published online 2025). doi: 10.1287/mnsc.2025.00510.

[20] C. von Lücken, L. Pereira, V. Dávalos, and F. López-Pires, “Improvement Strategies for Visualizing Solution Sets in Many-Objective Optimization Problems,” IEEE Access, vol. 12, pp. 142406-142418, 2024. doi: 10.1109/ACCESS.2024.3467997.

[21] Z. Osika, J. Zatarain Salazar, D. M. Roijers, F. A. Oliehoek, and P. K. Murukannaiah, “What Lies beyond the Pareto Front? A Survey on Decision-Support Methods for Multi-Objective Optimization,” in Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence (IJCAI), Macao, China, 2023, pp. 6741-6749. doi: 10.24963/ijcai.2023/755.

[22] C. H. Antunes and J. Clímaco, “Sensitivity analysis in MCDM using the weight space,” Operations Research Letters, vol. 12, no. 3, pp. 187-196, 1992. doi: 10.1016/0167-6377(92)90105-C.

[23] M. Makowski, J. Granat, A. Shekhovtsov, Z. Nahorski, and X. Zhao, “pyMCMA: Uniformly distributed Pareto-front representation,” SoftwareX, vol. 27, art. 101801, 2024. doi: 10.1016/j.softx.2024.101801.

[24] T. L. Saaty, “A Scaling Method for Priorities in Hierarchical Structures,” Journal of Mathematical Psychology, vol. 15, no. 3, pp. 234-281, 1977. doi: 10.1016/0022-2496(77)90033-5.

[25] G. Eichfelder, “Twenty years of continuous multiobjective optimization in the twenty-first century,” EURO Journal on Computational Optimization, vol. 9, art. 100014, 2021. doi: 10.1016/j.ejco.2021.100014.

[26] D. Bertsimas and J. N. Tsitsiklis, Introduction to Linear Optimization. Belmont, MA, USA: Athena Scientific, 1997. ISBN: 978-1-886529-19-9.

[27] G. L. Nemhauser and L. A. Wolsey, Integer and Combinatorial Optimization. New York, NY, USA: Wiley, 1988. ISBN: 978-0-471-82819-8.

[28] J. P. Vielma, “Mixed integer linear programming formulation techniques,” SIAM Review, vol. 57, no. 1, pp. 3-57, 2015. doi: 10.1137/130915303.

[29] D. Avis and K. Fukuda, “A pivoting algorithm for convex hulls and vertex enumeration of arrangements and polyhedra,” Discrete & Computational Geometry, vol. 8, pp. 295-313, 1992. doi: 10.1007/BF02293050.

[30] E. Boros, K. Elbassioni, V. Gurvich, L. Khachiyan, and K. Makino, “Dual-bounded generating problems: All minimal integer solutions for a monotone system of linear inequalities,” SIAM Journal on Computing, vol. 31, no. 5, pp. 1624-1643, 2002. doi: 10.1137/S0097539701388768.

[31] R. L. Smith, “Efficient Monte Carlo procedures for generating points uniformly distributed over bounded regions,” Operations Research, vol. 32, no. 6, pp. 1296-1308, 1984. doi: 10.1287/opre.32.6.1296.

[32] L. Lovász, “Hit-and-run mixes fast,” Mathematical Programming, vol. 86, pp. 443-461, 1999. doi: 10.1007/s101070050099.

[33] L. Lovász and S. Vempala, “Hit-and-run from a corner,” SIAM Journal on Computing, vol. 35, no. 4, pp. 985-1005, 2006. doi: 10.1137/S009753970544727X.

[34] J. A. Cornell, Experiments with Mixtures: Designs, Models, and the Analysis of Mixture Data, 3rd ed. New York, NY, USA: Wiley, 2002. ISBN: 978-0-471-39367-2.

[35] M. D. McKay, R. J. Beckman, and W. J. Conover, “A comparison of three methods for selecting values of input variables in the analysis of output from a computer code,” Technometrics, vol. 21, no. 2, pp. 239-245, 1979. doi: 10.1080/00401706.1979.10489755.

[36] B. Ganter and R. Wille, Formal Concept Analysis: Mathematical Foundations. Berlin, Germany: Springer, 1999. ISBN: 978-3-540-62771-5.

[37] R. Agrawal, T. Imieliński, and A. Swami, “Mining association rules between sets of items in large databases,” in Proc. ACM SIGMOD Int. Conf. Management of Data, 1993, pp. 207-216. doi: 10.1145/170036.170072.

[38] N. Pasquier, Y. Bastide, R. Taouil, and L. Lakhal, “Discovering frequent closed itemsets for association rules,” in Database Theory-ICDT’99, Lecture Notes in Computer Science, vol. 1540, 1999, pp. 398-416. doi: 10.1007/3-540-49257-7_25.

[39] C. Borgelt, “Frequent item set mining,” Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery, vol. 2, no. 6, pp. 437-456, 2012. doi: 10.1002/widm.1074.

[40] J. C. Gower, “A general coefficient of similarity and some of its properties,” Biometrics, vol. 27, no. 4, pp. 857-871, 1971. doi: 10.2307/2528823.

[41] C. Hennig, “Cluster-wise assessment of cluster stability,” Computational Statistics & Data Analysis, vol. 52, no. 1, pp. 258-271, 2007. doi: 10.1016/j.csda.2006.11.025.

[42] L. Kaufman and P. J. Rousseeuw, Finding Groups in Data: An Introduction to Cluster Analysis. New York, NY, USA: Wiley, 1990. ISBN: 978-0-471-87876-6.

[43] T. J. Santner, B. J. Williams, and W. I. Notz, The Design and Analysis of Computer Experiments, 2nd ed. New York, NY, USA: Springer, 2018.

[44] J. P. C. Kleijnen, Design and Analysis of Simulation Experiments, 2nd ed. Cham, Switzerland: Springer, 2015. ISBN: 978-3-319-18086-1.

[45] R. D. Peng, "Reproducible research in computational science," Science, vol. 334, no. 6060, pp. 1226-1227, 2011. doi: 10.1126/science.1213847.

[46] G. K. Sandve, A. Nekrutenko, J. Taylor, and E. Hovig, "Ten simple rules for reproducible computational research," PLOS Computational Biology, vol. 9, no. 10, e1003285, 2013. doi: 10.1371/journal.pcbi.1003285.

[47] G. Wilson et al., "Good enough practices in scientific computing," PLOS Computational Biology, vol. 13, no. 6, e1005510, 2017. doi: 10.1371/journal.pcbi.1005510.

[48] J. D. Hunter, "Matplotlib: A 2D graphics environment," Computing in Science & Engineering, vol. 9, no. 3, pp. 90-95, 2007. doi: 10.1109/MCSE.2007.55.

[49] P. Virtanen et al., "SciPy 1.0: Fundamental algorithms for scientific computing in Python," Nature Methods, vol. 17, pp. 261-272, 2020. doi: 10.1038/s41592-019-0686-2.

[50] W. McKinney, Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter, 3rd ed. Sebastopol, CA, USA: O'Reilly Media, 2022.